CORAL REEF DETECTION & CLASSIFICATION

دليل كامل للأربع تجارب: Pipeline + Architecture + Techniques + Evaluation

Four Experimental Pipelines - Full Technical Architecture Guide

Project Goal

اكتشاف الشعاب المرجانية داخل الصور والفيديو باستخدام Bounding Boxes، ثم قص منطقة الشعاب وتصنيف النوع، ثم تقييم النظام على الفيديو والـ Real-Time.

Experiment	Detector	Classifier	Primary Goal
1	RF-DETR-2XL	ConvNeXt-V2-Base	Maximum Accuracy
2	D-FINE-S	EfficientNet-B0	Parameter Efficiency
3	YOLO26n	MobileNetV4-Conv-S	Ultra-Fast / Edge
4	RF-DETR-M	ConvNeXt-V2-Tiny	Sweet Spot / Balance

Important Benchmark Note

الأرقام العامة في التقرير (COCO / ImageNet / latency) المنشورة تستخدم فقط كمرجع قبل التدريب. القرار النهائي يجب أن يعتمد على Coral Test Set واحدة ونفس الفيديوهات ونفس العتاد لجميع التجارب.

محتويات التقرير - CONTENTS

1. Common System Pipeline and Fair Experimental Protocol

2. Experiment 1 - Maximum Accuracy: RF-DETR-2XL + ConvNeXt-V2-Base

3. Experiment 2 - Parameter Efficiency: D-FINE-S + EfficientNet-B0

4. Experiment 3 - Ultra-Fast Edge: YOLO26n + MobileNetV4-Conv-S

5. Experiment 4 - Sweet Spot: RF-DETR-M + ConvNeXt-V2-Tiny

6. Cross-Experiment Comparison

7. Proper Ablation Study Design

8. Training and Evaluation Checklist

9. References and Technical Sources

1. COMMON SYSTEM PIPELINE

كل التجارب الأربعة تستخدم نفس الفكرة العامة. الاختلاف فقط في الـ Detector والـ Classifier. تثبيت بقية الخطوات ضروري حتى تكون المقارنة عادلة.

```
Underwater Image / Video
        |
        v
Preprocessing
(Resize + Normalize + Realistic Underwater Augmentation during training)
        |
        v
Object Detector
        |
        v
Coral Bounding Boxes
        |
        v
ROI Crop + 5-15% Context Padding
        |
        v
Species Classifier
        |
        v
Coral Species + Confidence
        |
        v
Video / Real-Time Overlay + FPS + Latency
```

1.1 Fair Comparison Rules

- نفس Train / Validation / Test split لكل التجارب، ويفضل التقسيم حسب الفيديو أو الموقع وليس Frame-by-frame لتجنب Data Leakage.
- نفس Detection annotations ونفس تعريف Class = coral إذا كان الـ Detector وظيفته تحديد مكان الشعاب فقط.
- نفس Classification species list ونفس crop-generation policy.
- نفس Test videos ونفس GPU/CPU ونسخة TensorRT/ONNX/PyTorch عند قياس السرعة.
- تسجيل image size، batch size، epochs، optimizer، learning rate، scheduler، seed، augmentation، checkpoint، confidence threshold لكل Run.
- القياس النهائي لا يعتمد على COCO/ImageNet benchmark؛ يعتمد على داتا الشعاب نفسها.

1.2 Common Data Techniques

- Underwater augmentation: brightness/gamma، contrast، blue-green color cast، mild haze/turbidity، slight blur، noise، scale، flip، small rotation.
- Small-object coverage: التأكد أن الـ Train/Test يحتويان على Small / Medium / Large coral، وليس فقط الشعاب الكبيرة القريبة.

- Negative images: صور رمل وصخور وأسماك ونباتات بحرية بدون Coral لتقليل False Positives.
- Class balance للتصنيف: weighted loss أو balanced sampler أو targeted augmentation عند نقص نوع معين.
- ROI crop realism: تدريب الـ Classifier على crops تشبه فعليًا مخرجات الـ Detector، وليس فقط صور نظيفة مثالية.
- Hard-case subsets: Clear water / Turbid / Low light / Far / Small / Crowded / Partial visibility.

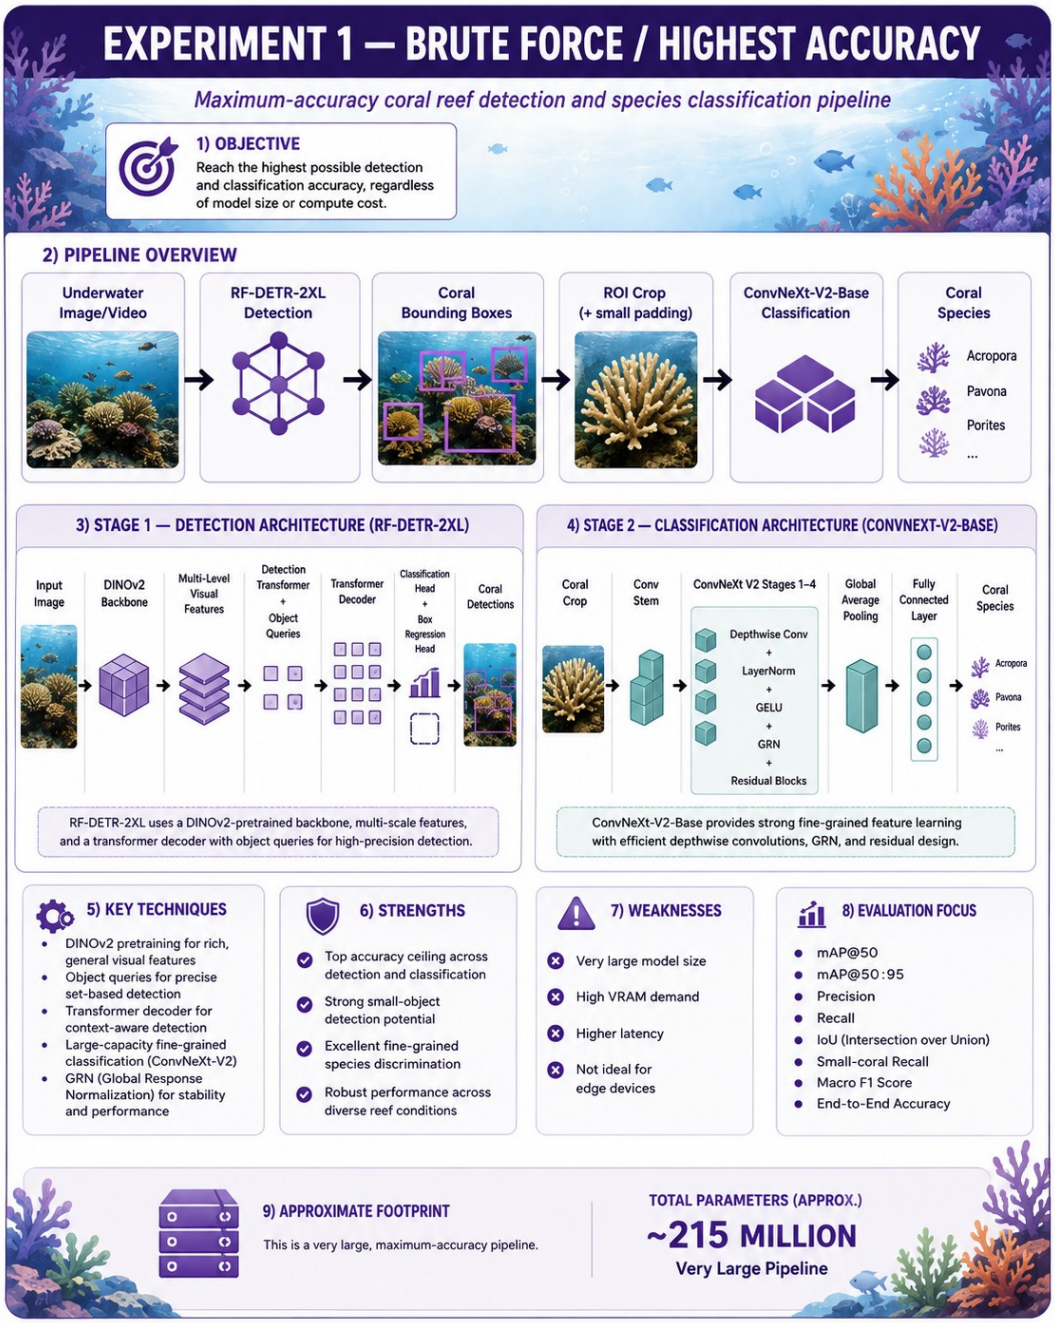
1.3 Common Evaluation

Layer	Core Metrics	Extra Coral-Specific Metrics
Detection	mAP@50, mAP@50:95, Precision, Recall, IoU	Small-Coral Recall, FP/FN by condition
Classification	Accuracy, Macro-F1, Precision, Recall, Confusion Matrix	Per-class Recall, Unknown/low-confidence errors
End-to-End	Correct box + correct species, total latency	Video stability, species flicker, missed-coral rate
Deployment	FPS, latency, VRAM/RAM, model size	Edge readiness, power/thermal constraints

2. EXPERIMENT 1 - MAXIMUM ACCURACY

Configuration

Detector: RF-DETR-2XL | Classifier: ConvNeXt-V2-Base | Goal: أعلى دقة ممكنة حتى لو كان الحجم والـ GPU cost مرتفعين.



Experiment 1 visual summary - RF-DETR-2XL -> ROI Crop -> ConvNeXt-V2-Base

ملاحظة: الحجم التقريبي للنظام عند استخدام RF-DETR-2XL (126.9M) مع ConvNeXt-V2-Base (~88.7M) يقارب 215.6M parameter. هذه التجربة تمثل Accuracy Ceiling وليس Edge deployment.

2.1 Detection Architecture - RF-DETR-2XL

```
Input image (reference benchmark resolution: 880 x 880)
  -> DINOv2-pretrained visual backbone
  -> Rich visual feature representation
  -> Detection Transformer
       + learned object queries
       + global/context interaction
  -> Transformer decoder
  -> Set-based predictions
       -> Classification head
       -> Bounding-box regression head
  -> Coral bounding boxes + confidence
```

Native Model Techniques

- DINOv2 pretrained backbone: يبدأ من visual representations قوية بدل التدريب من الصفر، ثم يتم Fine-tuning على الشعاب.
- DETR-style object queries: كل Query تحاول تمثيل كائن محتمل، والنظام يتعلم مجموعة تنبؤات مباشرة بدل منطق dense anchors التقليدي.
- Transformer context modeling: الانتباه يسمح للنموذج بربط أجزاء بعيدة من الصورة، وهو مفيد في المشاهد المعقدة والمتداخلة.
- Set-based detection: يتعامل مع التنبؤات كمجموعة Objects ويقلل الاعتماد على heuristics التقليدية في matching.
- High-capacity model scaling: نسخة 2XL هدفها رفع سقف الدقة، مع تكلفة أعلى في الذاكرة والـ latency.
- Higher reference input resolution: benchmark المنشور للـ 2XL يستخدم 880x880، ما يساعد على الاحتفاظ بتفاصيل أكثر مقارنة بمدخلات أصغر، لكنه يزيد الحسابات.

Recommended Coral Fine-Tuning Techniques

- Transfer Learning من pretrained weights، ثم Fine-tune جميع الطبقات بعد warm-up قصير إذا كانت الموارد تسمح.
- Mixed Precision (AMP) لتقليل VRAM وتسريع التدريب بدون تغيير الهدف العلمي.
- Gradient accumulation إذا كان batch size الفعلي صغيرًا بسبب حجم 2XL.
- Learning-rate warm-up + scheduler، مع حفظ Best Validation Checkpoint بدل الاعتماد على آخر Epoch.
- Realistic underwater augmentation مع تجنب تشويه morphology الخاصة بالشعاب.

- Hard-example mining يدويًا بعد أول baseline: إعادة إدخال حالات Small / Turbid / Low-light / Crowded التي يفشل فيها النموذج.
- Threshold tuning على Validation set: ضبط confidence threshold لتحقيق trade-off مناسب بين Recall و False Positives.

2.2 ROI Crop Stage

```
Detector box [x1, y1, x2, y2]
  -> add context padding (start with 5-15%)
  -> clip box to image boundaries
  -> crop detected coral
  -> resize with classifier-specific preprocessing
  -> classifier input
```

- Padding صغير يحافظ على morphology والسياق القريب بدل crop شديد الضيق.
- يجب اختبار 0% مقابل 5% مقابل 10% أو 15% كـ ablation صغيرة لأن زيادة الخلفية قد تضر التصنيف.
- في التدريب النهائي للـ Classifier، استخدم بعض crops الناتجة من Detector فعلي، وليس فقط Ground-Truth crops.

2.3 Classification Architecture - ConvNeXt-V2-Base

```
Coral crop
  -> Conv stem
  -> Stage 1
  -> Downsample
  -> Stage 2
  -> Downsample
  -> Stage 3
  -> Downsample
  -> Stage 4
  -> Global Average Pooling
  -> Linear classification head
  -> Coral species probabilities

Typical ConvNeXt-V2 block:
7x7 Depthwise Conv
  -> LayerNorm
  -> 1x1 channel expansion
  -> GELU
  -> GRN (Global Response Normalization)
  -> 1x1 projection
  -> Residual connection
```

Native Model Techniques

- Fully Convolutional Masked Autoencoder (FCMAE) pretraining framework في عائلة ConvNeXt V2.
- GRN - Global Response Normalization: تعزز competition بين قنوات الـ features وتقلل feature redundancy.
- Large-kernel depthwise convolution (7x7): توسع receptive field بكفاءة أفضل من convolution كثيف كبير.
- Inverted-bottleneck style channel expansion ثم projection: يرفع قدرة تمثيل features داخل البلوك.
- GELU activation وLayerNorm: تصميم حديث مستقر مناسب لعائلة ConvNeXt.
- Residual connections: تسهل optimization في الشبكات العميقة.

Recommended Classification Training Techniques

- Replace classification head بعدد species الفعلي ثم Fine-tune من pretrained checkpoint.
- Cross-Entropy + Label Smoothing كبداية؛ استخدم class weights إذا ظهر imbalance واضح.
- Balanced sampler عند وجود أنواع قليلة بدل زيادة Augmentation بشكل غير واقعي.
- MixUp/CutMix يمكن اختباره، لكن بحذر في Fine-Grained Coral classification لأن دمج نوعين بصريًا قد يخلق صورًا غير واقعية.
- Early stopping + best checkpoint based on Macro-F1 أو balanced accuracy وليس Accuracy فقط.
- Confusion-matrix-driven data collection: زود البيانات للأنواع التي يخلط بينها النموذج باستمرار.

2.4 Experiment 1 Evaluation Focus

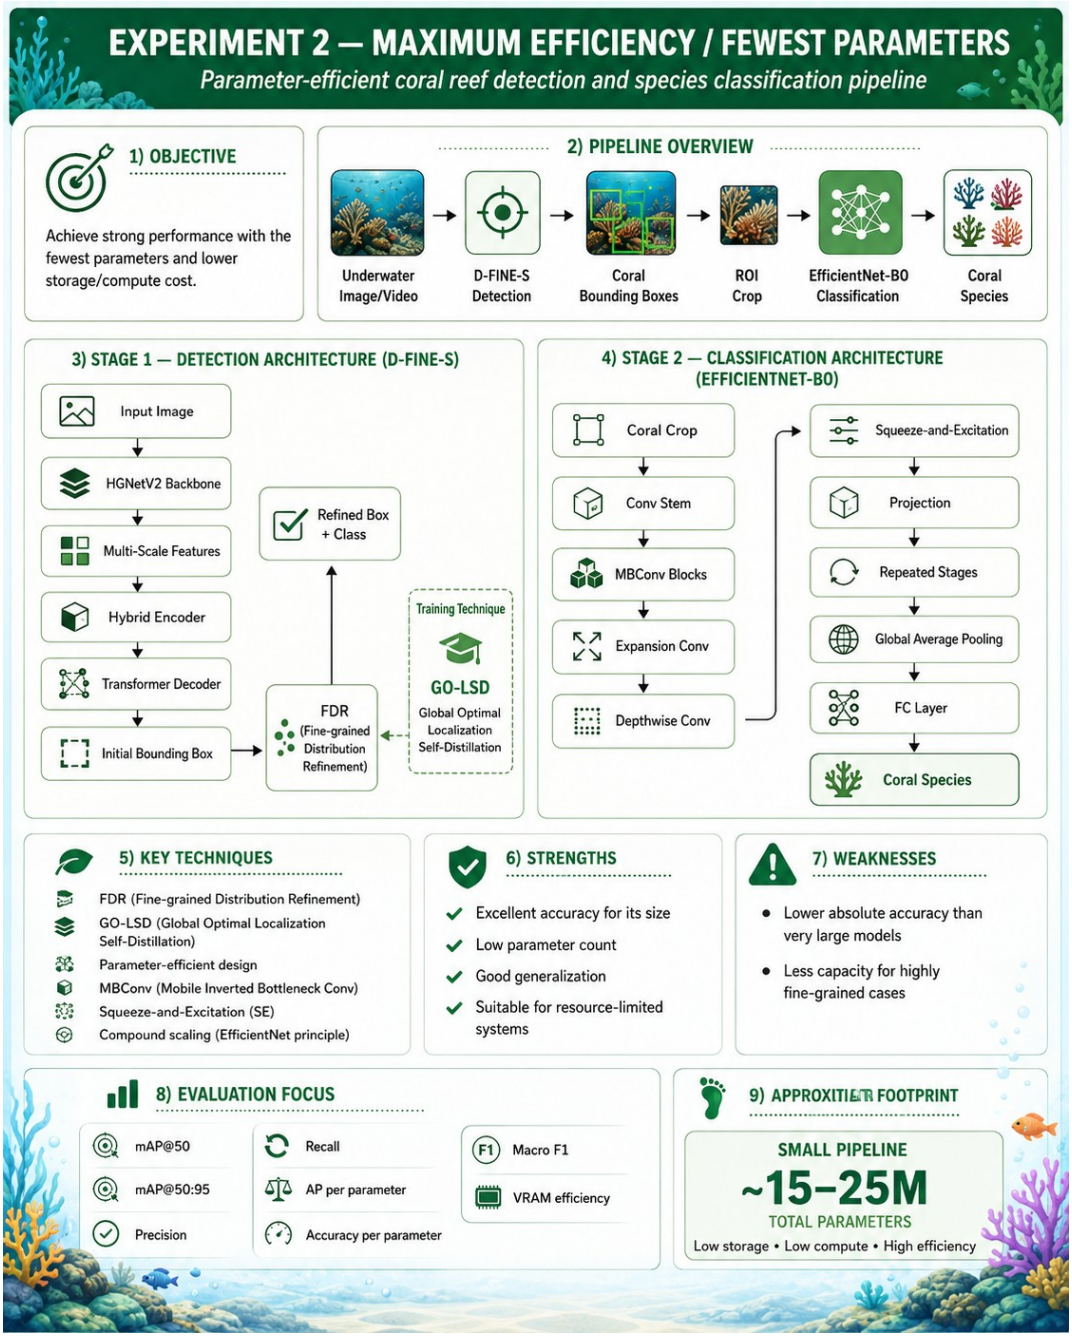
- Detection: أعلى mAP@50:95 وSmall-Coral Recall ممكن.

- Classification: Macro-F1 + Per-Class Recall + Confusion Matrix.
- End-to-End: نسبة coral التي تم اكتشافها وتصنيف species لها بشكل صحيح.
- Cost: VRAM، training time، latency، FPS. الهدف هنا معرفة تكلفة الوصول لسقف الدقة.

3. EXPERIMENT 2 - PARAMETER EFFICIENCY

Configuration

Detector: D-FINE-S | Classifier: EfficientNet-B0 | Goal: أعلى performance ممكن لكل Parameter مع نموذج صغير نسبيًا.



Experiment 2 visual summary - D-FINE-S -> ROI Crop -> EfficientNet-B0

الحجم التقريبي عند تثبيت الاختيار على D-FINE-S (~10.2M) + EfficientNet-B0 (~5.3M) يساوي تقريبًا 15.5M parameter.

لذلك استخدم رقمًا ثابتًا في التقرير بدل range واسع.

3.1 Detection Architecture - D-FINE-S

```
Input image
  -> HGNetV2 backbone
  -> multi-scale feature maps
  -> hybrid encoder
  -> object queries
  -> transformer decoder layer 1
  -> initial bounding boxes
  -> FDR: fine-grained probability distributions for box boundaries
  -> iterative distribution refinement across decoder layers
  -> final class + refined box predictions
```

Native Model Techniques

- FDR - Fine-grained Distribution Refinement: يحول box regression من توقع إحداثيات مباشرة فقط إلى تحسين توزيعات احتمالية دقيقة لحدود الصندوق عبر decoder layers.
- GO-LSD - Global Optimal Localization Self-Distillation: ينقل معرفة localization من التوزيعات النهائية الأكثر دقة إلى الطبقات الأقل عمقًا أثناء التدريب.
- DETR query-based detection: object queries + transformer decoder للتنبؤ بالكائنات.
- Hybrid encoder: دمج وتمرير features متعددة المقاييس قبل decoder.
- Lightweight optimization: D-FINE صمم لتحسين accuracy-speed balance في الوحدات الحسابية المكلفة.
- Optional Objects365 pretraining checkpoint: بعض النتائج الأعلى المنشورة لـ D-FINE-S تعتمد على pretraining إضافي؛ لذلك يجب تسجيل checkpoint بدقة.

Why FDR Can Matter for Coral

- Bounding boxes للشعاب قد تكون صعبة لأن الشكل غير منتظم وحدودها البصرية لا تشبه objects الصلبة.
- Small coral يحتاج localization دقيق حتى لا ينتج crop ناقص يضر الـ Classifier.
- لكن هذه فوائد متوقعة يجب إثباتها على Coral Test Set، وليس افتراضها من COCO فقط.

Recommended Coral Fine-Tuning Techniques

- ابدأ من checkpoint موثق المصدر، وسجل هل هو COCO-only أو Objects365+COCO.
- استخدم نفس augmentation ونفس split المستخدمين في بقية detectors لضمان عدالة المقارنة.
- راقب AP_small أو Small-Coral Recall بشكل منفصل عن mAP العام.
- AMP + best-checkpoint selection + fixed random seeds.

- حلل box localization errors وليس فقط missed detections لأن هدف المرحلة التالية يعتمد على جودة crop.

3.2 Classification Architecture - EfficientNet-B0

```
Coral crop
  -> Conv stem
  -> repeated MBConv stages
       Expansion 1x1 Conv
       -> Depthwise Conv
       -> BatchNorm + SiLU/Swish
       -> Squeeze-and-Excitation
       -> Projection Conv
       -> Residual connection (where compatible)
  -> Global Average Pooling
  -> Dropout
  -> Fully Connected species head
```

Native Model Techniques

- MBConv - Mobile Inverted Bottleneck Convolution: توسعة channels ثم depthwise convolution ثم projection.
- Depthwise separable convolution: تقلل الحسابات والمعلمات مقارنة بـ standard convolution.
- Squeeze-and-Excitation (SE): تعيد وزن القنوات بناءً على أهميتها.
- Swish/SiLU activation: nonlinearity سلسة استخدمت في EfficientNet.
- Compound Scaling: المبدأ الأساسي لعائلة EfficientNet يوازن depth + width + resolution بدل تكبير بعد واحد فقط.
- Residual / skip connections في البلوكات المناسبة.

Recommended Training Techniques

- Transfer Learning من ImageNet ثم استبدال الرأس بعدد species.
- Image size 224 كبداية ثم اختبار resolution أعلى إذا كانت فروق الأنواع تعتمد على تفاصيل دقيقة.
- Weighted Cross-Entropy أو balanced sampling عند class imbalance.
- Regularization معتدل: dropout / weight decay / label smoothing.
- Underwater color augmentation بحذر لأن اللون قد يكون feature مفيد لبعض الأنواع.

3.3 Efficiency Metrics

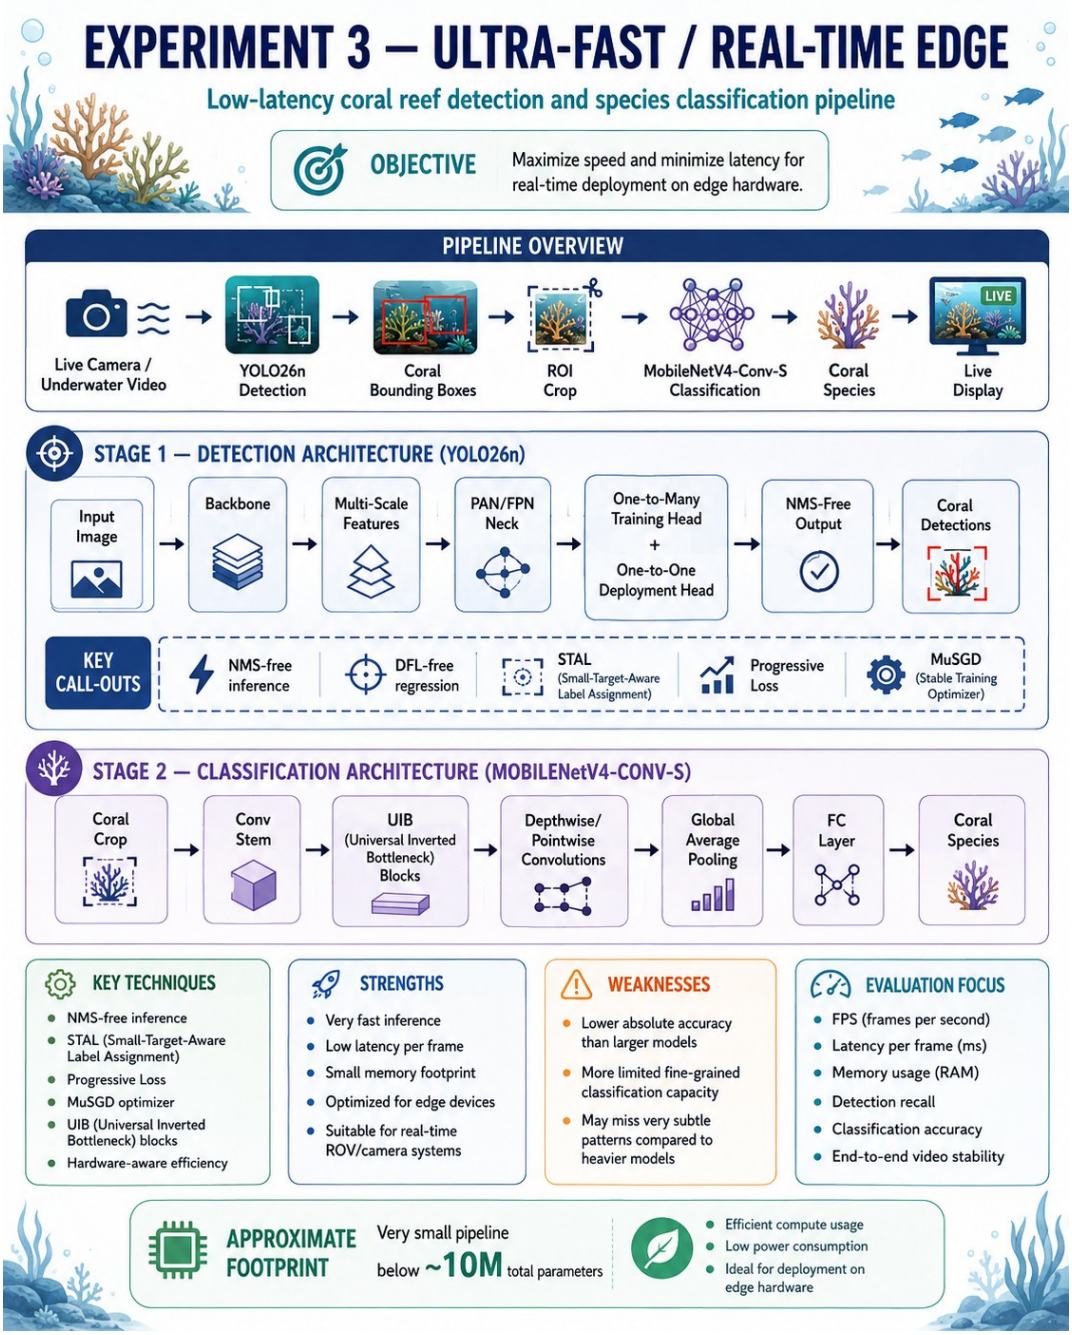
- Detection AP per million parameters.
- Classification Macro-F1 per million parameters.
- Total model size (MB) per unit of end-to-end accuracy.

- VRAM and latency normalized to the same hardware.
- هذه التجربة تفوز إذا حققت أداء قريبًا من النماذج الكبيرة مع تكلفة أقل بوضوح.

4. EXPERIMENT 3 - ULTRA-FAST / REAL-TIME EDGE

Configuration

Detector: YOLO26n | Classifier: MobileNetV4-Conv-S | Goal: أعلى FPS وأقل latency وحجم صغير مناسب للـ Edge / ROV / Jetson-class deployment.



Experiment 3 visual summary - YOLO26n -> ROI Crop -> MobileNetV4-Conv-S

الحجم التقريبي: YOLO26n ~2.4M + MobileNetV4-Conv-S ~3.8M = حوالي 6.2M parameter. لذلك هذه أصغر Pipeline من الأربع.

4.1 Detection Architecture - YOLO26n

```
Input 640 x 640
  -> Conv stem / downsampling
  -> C3k2 backbone blocks
  -> SPPF with residual shortcut
  -> C2PSA attention
  -> multi-scale P3 / P4 / P5 features
  -> FPN top-down fusion
  -> PAN bottom-up fusion
  -> end-to-end detection head
       Training: auxiliary one-to-many branch
       Deployment: one-to-one branch
       Box regression: DFL-free (reg_max=1)
  -> direct NMS-free detections
```

Native Model Techniques

- C3k2 backbone/neck blocks: CSP-style efficient feature extraction مستخدمة في YOLO11 وYOLO26.
- SPPF + residual shortcut: توسيع receptive field عبر fast spatial pyramid pooling مع shortcut في YOLO26.
- C2PSA attention: position-sensitive attention بعد SPPF لتحسين feature interaction.
- FPN + PAN multi-scale fusion: دمج semantics عالية المستوى مع localization عالية الدقة عبر P3/P4/P5.
- Anchor-free decoupled detection head: فروع box/class منفصلة بدون anchor-box hyperparameters التقليدية.
- End-to-End one-to-one head: المسار الافتراضي للاستدلال يخرج prediction واحدًا لكل object بدون NMS خارجي.
- Auxiliary one-to-many head during training: يساعد الإشراف أثناء التدريب ثم يمكن إزالته عند fused deployment.
- DFL-free regression: إزالة Distribution Focal Loss من head وتبسيط export/inference.
- STAL - Small-Target-Aware Label Assignment: يحسن positive label coverage للأجسام الصغيرة، مهم جدًا للشعاب الصغيرة.
- Progressive Loss: يغيّر وزن الإشراف تدريجيًا باتجاه head المستخدم وقت inference.
- MuSGD optimizer: recipe تدريب تجمع SGD مع Muon-inspired optimization.

Recommended Coral / Edge Techniques

- ابدأ بـ YOLO26n 640 كـ real-time baseline، ثم اختبر input size أعلى فقط إذا Small-Coral Recall ضعيف ويمكن تحمل latency.

- اختبر YOLO26-P2 كـ ablation للأجسام الصغيرة إذا كانت الشعاب الدقيقة هي نقطة الفشل، مع العلم أنه يزيد الحسابات.
- TensorRT FP16 للتسريع على NVIDIA؛ ويمكن اختبار INT8 لاحقًا بشرط calibration dataset واقعية.
- Measure latency end-to-end وليس detector latency فقط: preprocessing + detection + crop + classification + overlay.
- Batch=1 عند قياس الـ live latency لأن batch throughput لا يمثل real-time camera latency.
- استخدم asynchronous video capture/inference فقط كتحسين deployment منفصل عن المقارنة الأساسية.

4.2 Classification Architecture - MobileNetV4-Conv-S

```
Coral crop
  -> Conv stem
  -> UIB blocks (Universal Inverted Bottleneck)
       optional pointwise expansion
       -> depthwise / ExtraDW operations as searched
       -> pointwise projection
  -> efficient convolutional stages
  -> Global Average Pooling
  -> linear species head
```

Native Model Techniques

- UIB - Universal Inverted Bottleneck: search block مرنة توحد أفكار Inverted Bottleneck و ConvNeXt/FFN-style وdesign Extra Depthwise variant.
- Depthwise and pointwise convolutions: تقليل MACs والمعلمات.
- Hardware-aware Neural Architecture Search: MobileNetV4 صممت لتكون فعالة عبر mobile CPU/GPU/DSP/accelerators وليس فقط FLOPs نظريًا.
- Model family includes Mobile MQA attention للنسخ Hybrid؛ لكن Conv-S المختارة هنا convolutional، لذلك لا ننسب Mobile MQA مباشرة لهذه النسخة.
- Distillation كان جزءًا من منهج الورقة لتحسين بعض النماذج؛ عند Fine-tuning يمكنك اختباره كتقنية إضافية لكن ليس شرطًا في baseline.

Recommended Edge Classification Techniques

- استخدم preprocessing الرسمي للـ pretrained checkpoint (resize/normalization) كأساس.
- اختبر FP16 ثم INT8 quantization مع مقارنة drop في Macro-F1 وper-class recall.
- حافظ على crop resolution صغيرة نسبيًا مثل 224 كبداية، ثم قارن 224 مقابل 256/320 إذا الأنواع متشابهة جدًا.

- لو عدد crops في frame كبير، classifier latency قد يصبح bottleneck حتى لو detector سريع؛ لذلك سجل latency حسب عدد detections/frame.

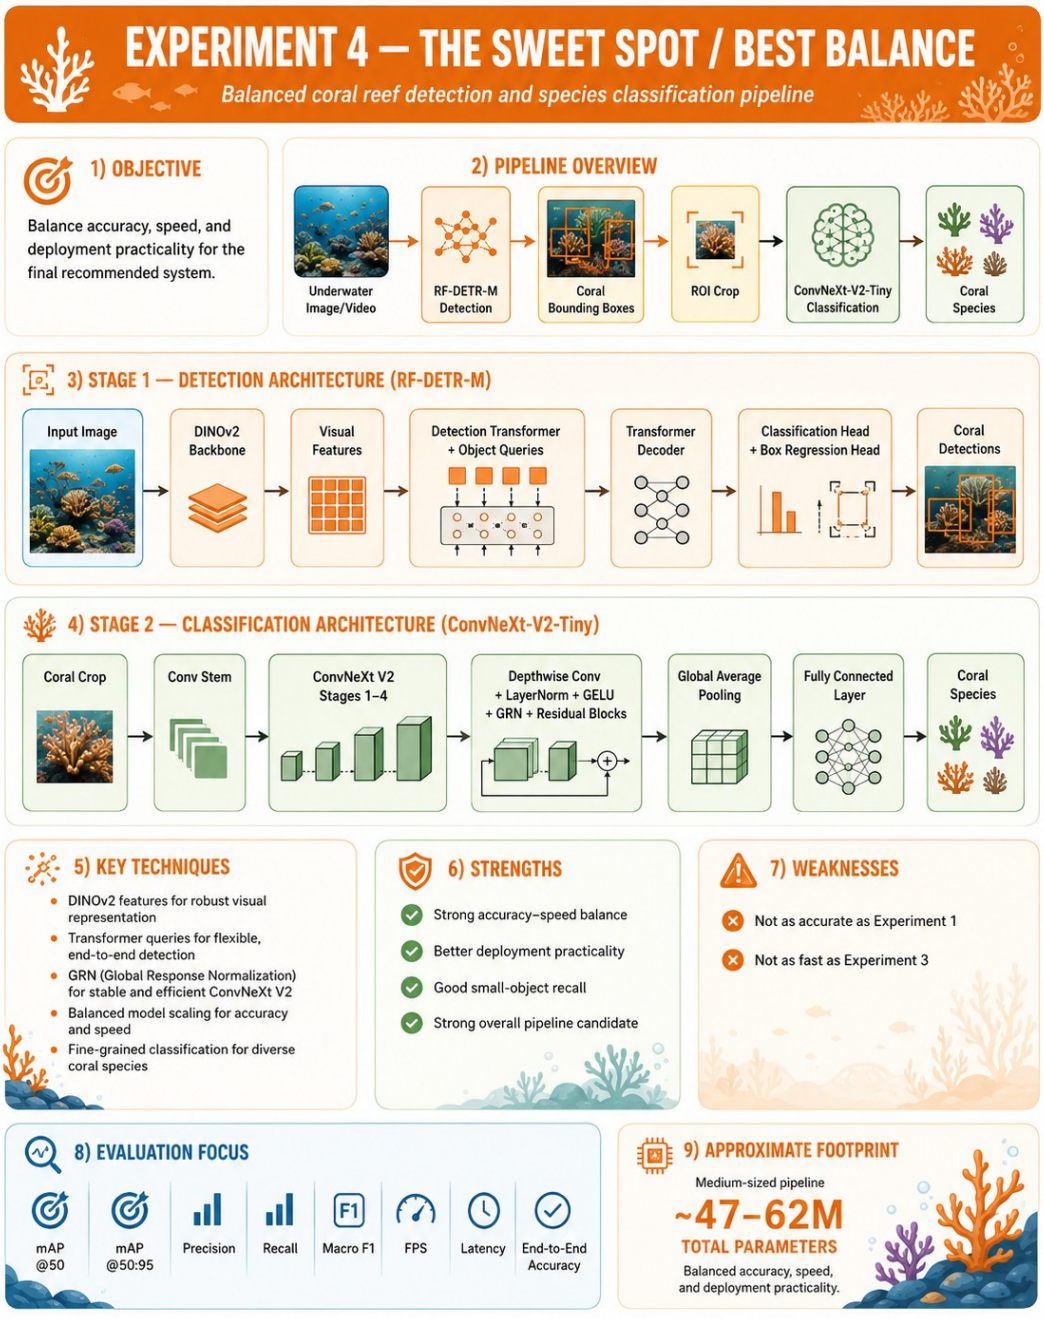
4.3 Real-Time Evaluation Focus

- FPS المستمر على فيديو طويل، وليس burst قصير.
- Median وP95 latency per frame، لأن المتوسط وحده يخفي spikes.
- RAM/VRAM، GPU/CPU usage، وحرارة الجهاز عند edge deployment.
- Detection stability وclassification flicker بين frames.
- End-to-end throughput مع 1، 5، 10+ coral crops في frame.

5. EXPERIMENT 4 - THE SWEET SPOT / BEST BALANCE

Configuration

Detector: RF-DETR-M | Classifier: ConvNeXt-V2-Tiny | Goal: أفضل توازن بين accuracy، speed، memory، وقابلية النشر.



Experiment 4 visual summary - RF-DETR-M -> ROI Crop -> ConvNeXt-V2-Tiny

تصحيح مهم للرسم: هذا التقرير يثبت Experiment 4 على RF-DETR-M وليس RF-DETR-M أو D-FINE-M. لذلك الحجم التقريبي للنظام = 28.64M + 33.7M = حوالي 62.3M parameter. الـ range الظاهر في الصورة جاء من النسخة القديمة التي كانت تسمح بـ D-FINE-M كبديل.

5.1 Detection Architecture - RF-DETR-M

```
Input image (reference benchmark resolution: 576 x 576)
  -> DINOv2-pretrained backbone
  -> visual features
  -> detection transformer
       + object queries
  -> transformer decoder
  -> class head + box regression head
  -> coral detections
```

Native Model Techniques

- نفس الأساس المعماري لـ RF-DETR: DINOv2 feature backbone + DETR-style queries + transformer decoder.
- Model scaling: الهدف الحفاظ على representation قوية مع latency وmemory أقل من 2XL أصغر كثيرًا.
- Set-based / query-based detection مناسب للمقارنة مع YOLO dense multi-scale head و D-FINE distribution refinement.

Recommended Fine-Tuning Techniques

- Transfer learning مع same augmentation/split المستخدمة في Experiment 1.
- اختبار 576 المرجعي مقابل resolution أعلى مثل 704 أو custom size إذا كان Small-Coral Recall يحتاج تحسين، مع تسجيل latency.
- Hard-case retraining على underwater failure modes.
- AMP + checkpointing + learning-rate scheduler + fixed seeds.
- Confidence tuning منفصل لـ still images ولـ video إذا احتجت، مع منع استخدام test set في tuning.

5.2 Classification Architecture - ConvNeXt-V2-Tiny

```
Coral crop
  -> Conv stem
  -> ConvNeXt-V2 Stage 1
  -> downsample
  -> Stage 2
  -> downsample
  -> Stage 3
  -> downsample
  -> Stage 4
  -> Global Average Pooling
  -> linear species head

Core block:
7x7 depthwise conv -> LayerNorm -> expansion -> GELU -> GRN -> projection -> residual
```

Native Model Techniques

- FCMAE-pretrained ConvNeXt V2 family.
- GRN لتحسين inter-channel feature competition.
- Large-kernel depthwise convolution بكفاءة أعلى من dense large kernels.
- Residual hierarchical stages مع downsampling تدريجي.
- Tiny scale (~28.64M) يعطي capacity قوية للتصنيف الدقيق مع تكلفة أقل بوضوح من Base.

Why This Is the Main Final Candidate

- Detector أقوى بكثير من nano detector من ناحية capacity، لكنه أسرع وأصغر كثيرًا من RF-DETR-2XL.
- Classifier Tiny يحتفظ بخصائص ConvNeXt V2 المهمة للتفريق بين textures والـ morphology، بدون حجم Base.
- يتيح مساحة للـ real-time أو near-real-time بعد optimization، مع accuracy محتملة أعلى من Experiment 3.
- لكن يجب إثبات الـ Sweet Spot بالقياس الفعلي؛ الاسم هدف تجريبي وليس نتيجة مسبقة.

5.3 Evaluation Focus

- End-to-end accuracy مقابل Experiment 1.
- FPS/latency مقابل Experiment 3.
- AP/M parameters مقابل Experiment 2.
- Small-coral recall وMacro-F1 كأهم مؤشرين للجودة العملية.
- إذا اقتربت الدقة من Experiment 1 مع latency مقبول، تكون هذه أقوى مرشح للنظام النهائي.

6. CROSS-EXPERIMENT COMPARISON

Exp	Detector	Det. Params	Classifier	Cls. Params	Approx. Total
1	RF-DETR-2XL	126.9M	ConvNeXt-V2-Base	88.7M	~215.6M
2	D-FINE-S	~10.2M	EfficientNet-B0	~5.3M	~15.5M
3	YOLO26n	2.4M	MobileNetV4-Conv-S	3.8M	~6.2M
4	RF-DETR-M	33.7M	ConvNeXt-V2-Tiny	28.64M	~62.3M

Experiment	Expected Strength	Main Risk	Decision Question
1 - Accuracy	Maximum capacity	VRAM/latency	كم هو سقف الدقة؟

Experiment	Expected Strength	Main Risk	Decision Question
2 - Efficiency	Best performance/parameter	Lower absolute ceiling	هل نقترب من الكبير بحجم صغير؟
3 - Edge	Highest speed / smallest footprint	May lose subtle detail	هل يحقق real-time بجودة مقبولة؟
4 - Balance	Strong accuracy-speed balance	Neither absolute fastest nor largest	هل هو أفضل نظام نهائي؟

6.1 What Must Be Logged for Every Run

- .Model + exact checkpoint + pretraining dataset
- .Input resolution, batch size, epochs, optimizer, LR, scheduler, seed
- .Data augmentation configuration
- .Best validation epoch and checkpoint criterion
- .Detector mAP50, mAP50:95, Precision, Recall, Small-Coral Recall
- .Classifier Accuracy, Macro-F1, Per-Class Recall, Confusion Matrix
- .End-to-End accuracy, FPS, median latency, P95 latency, VRAM/RAM
- .Per-condition results: clear/turbid, normal/low light, small/large, near/far, single/crowded

6.2 Recommended Final Scorecard

Metric	Why It Matters	Direction
Small-Coral Recall	Missed small coral cannot reach classifier	Higher is better
mAP@50:95	Overall detection/localization quality	Higher
Macro-F1	Fair classification across imbalanced species	Higher
End-to-End Correct %	Measures full system success	Higher
Median/P95 Latency	Real-time responsiveness and stability	Lower
VRAM/RAM	Deployment feasibility	Lower
Parameters / Model MB	Storage and edge footprint	Lower

7. PROPER ABLATION STUDY DESIGN

الأربع Pipelines السابقة هي System-level trade-off experiments. لكي نسمي جزءًا من الدراسة Ablation بشكل دقيق، يجب تثبيت جزء وتغيير جزء واحد فقط.

7.1 Detector Ablation - Fix the Classifier

```
Fixed classifier: ConvNeXt-V2-Tiny

RF-DETR-2XL ---------\
D-FINE-S --------------> same crop policy -> ConvNeXt-V2-Tiny -> compare
YOLO26n --------------/
RF-DETR-M ------------/
```

- نفس classification weights أو إعادة تدريب classifier مرة واحدة على نفس training crops.
- قارن detector recall وجودة الـ crops وتأثيرها على end-to-end species accuracy.
- ده يحدد هل فرق النظام سببه detector فعلًا.

7.2 Classifier Ablation - Fix the Detector

```
Fixed detector: RF-DETR-M

RF-DETR-M -> same detected crops -> ConvNeXt-V2-Base
                                 -> EfficientNet-B0
                                 -> MobileNetV4-Conv-S
                                 -> ConvNeXt-V2-Tiny
```

- قارن latency، per-class recall، Macro-F1 لكل crop، وthroughput عند تعدد detections في frame.
- ده يحدد تكلفة وفائدة زيادة classifier capacity.

7.3 Small but Valuable Micro-Ablations

- Crop padding: 0% vs 5% vs 10%/15%.
- Classifier resolution: 224 vs 256/320.
- Detector input resolution: baseline vs higher resolution.
- With vs without underwater augmentation.
- YOLO26n vs YOLO26n-P2 for small objects.
- FP16 vs INT8 for edge deployment (Experiment 3).

8. TRAINING AND EVALUATION CHECKLIST

8.1 Before Training

- .Verify all detection boxes and remove annotation errors
- .Build data diversity report and identify underrepresented conditions
- .Split by video/site to prevent leakage
- .Freeze final Test set before any model tuning
- .Prepare class distribution report for classification
- .Define one reproducible experiment config file per run

8.2 During Detection Training

- .Monitor train/val losses and mAP curves
- .Save best checkpoint by validation mAP@50:95 or chosen criterion
- .Inspect false positives/false negatives every few epochs or at checkpoints
- .Track Small-Coral Recall separately
- .Keep screenshots/examples of common errors for the report

8.3 During Classification Training

- .Monitor Macro-F1, not Accuracy alone
- .Save confusion matrix at best checkpoint
- .Check class-wise recall and identify confusing species pairs
- .Inspect model confidence distribution; consider an Unknown/low-confidence policy later
- .Validate on detector-like crops, not only perfect ground-truth crops

8.4 Final Video / Real-Time Test

- .Use unseen videos from different scenes if possible
- .Measure FPS, median latency, P95 latency, memory, and stability over time
- .Count species flicker on the same tracked coral across consecutive frames
- .Report failure cases with example frames and condition labels

9. REFERENCES AND TECHNICAL SOURCES

[R1] RF-DETR official GitHub / benchmarks

https://github.com/roboflow/rf-detr

[R2] RF-DETR benchmark table

https://github.com/roboflow/rf-detr/blob/develop/docs/learn/benchmarks.md

[R3] D-FINE official paper - Fine-grained Distribution Refinement and GO-LSD

https://arxiv.org/abs/2410.13842

[R4] D-FINE official GitHub

https://github.com/Peterande/D-FINE

[R5] Ultralytics YOLO26 official docs

https://docs.ultralytics.com/models/yolo26/

[R6] Ultralytics YOLO architecture guide

https://docs.ultralytics.com/guides/yolo-architecture/

[R7] ConvNeXt V2 paper - FCMAE and GRN

https://arxiv.org/abs/2301.00808

[R8] EfficientNet paper - Compound Scaling

https://arxiv.org/abs/1905.11946

[R9] MobileNetV4 paper - UIB / mobile-efficient design

https://arxiv.org/abs/2404.10518

[R10] timm ConvNeXt-V2-Base model card / parameters

https://huggingface.co/timm/convnextv2_base.fcmae_ft_in1k

[R11] timm MobileNetV4-Conv-S model card / parameters

https://huggingface.co/timm/mobilenetv4_conv_small.e2400_r224_in1k

Source Interpretation Rule

أي رقم benchmark في هذا التقرير هو Reference قبل Fine-tuning فقط. النتائج الأكاديمية للمشروع يجب أن تكون من نفس Coral Test Set ونفس hardware measurement protocol.