Coral Reef AI Project Plan

Detailed Detection & Classification Plan

خطة تفصيلية لتجهيز البيانات، تدريب النماذج، التقييم، الدمج، الفيديو والـ Real-Time

الهدف النهائي: اكتشاف الشعاب المرجانية داخل الصور أو الفيديو بـ Bounding Boxes، ثم قص المناطق المكتشفة وتصنيف نوع الشعاب المرجانية، ثم تشغيل النظام على فيديوهات حقيقية وفي الزمن الحقيقي.

Data -> Detection -> Evaluation -> Classification -> Evaluation -> Integration -> Video -> Real-Time -> Final Evaluation

1. Project Architecture

Raw Images / Videos -> Detection Data -> YOLO Detector -> Coral Crops -> Classification Data -> Classifier -> Integrated Pipeline -> Video -> Real-Time

تقسيم المسؤوليات: الـ Detection Model يجيب على سؤال: "أين توجد الشعاب؟". الـ Classification Model يجيب على سؤال: "ما نوع الشعاب المكتشفة؟". الفصل بين المهمتين يجعل التشخيص والتحسين أسهل.

Detection Track

2. Detection Data Preparation

الهدف: تحويل الصور والفيديوهات الخام إلى Dataset قابلة لتدريب YOLO بشكل نظيف ومتسق وبدون Data Leakage.

2.1 Data Inventory & Understanding

1. حصر المصادر: تجميع كل الصور والفيديوهات، وتسجيل مصدر كل ملف، الكاميرا، الموقع أو الـ dive إن كان متاحًا، والدقة Resolution.

2. فحص الـ **labels** الحالية: التأكد هل الـ Dataset عليها Bounding Boxes بالفعل، وما هي الصيغة: YOLO أو COCO أو Pascal VOC، وما هي أسماء الـ classes.

3. قرار الـ **Detection Classes**: لـ pipeline المقترحة نبدأ غالبًا بـ Class واحدة: coral. النوع Species يُترك للـ Classification Model.

4. إحصاء البيانات: عدد الصور، عدد الفيديوهات، عدد الـ coral instances، الصور السلبية التي لا تحتوي Coral، وتوزيع أحجام الـ objects.

5. فحص الظروف: تصنيف الصور حسب clear/turbid water، normal/low light، near/far، small/large coral، والخلفية crowded scenes، camera angle.

2.2 Frame Extraction from Videos

- لا نستخدم كل Frame لأن الفريمات المتتالية شبه متطابقة وتضيف redundancy أكثر من معلومات جديدة.
- نبدأ باستخراج Frame كل 0.5-2 ثانية حسب سرعة حركة الكاميرا، ثم نراجع التنوع بصريًا.
- الفريمات من نفس الفيديو أو نفس الـ sequence يجب أن تبقى في Split واحدة؛ لا توزع Frames متجاورة بين Train وTest.
- نحتفظ بمصدر كل Frame في metadata حتى يمكن منع الـ leakage لاحقًا.

2.3 Cleaning Rules

Metric / Check	What it tells us	Why it matters
Completely black / corrupted	لا تحتوي معلومات قابلة للتعلم	Remove
Severely unusable blur	فيها coral لا يمكن للإنسان تحديد	Remove
Low light but visible	حالة واقعية صعبة	Keep
Turbid water but visible	حالة واقعية صعبة	Keep
Near-duplicate frames	تكرر نفس المشهد	Deduplicate / keep representative frames
No coral image	Negative sample	Keep with no boxes

2.4 Bounding Box Annotation Policy

- كل coral instance واضح يحصل على Bounding Box مستقل.
- الـ Box تكون tight قدر الإمكان حول الشعاب بدون قص أجزاء منها وبدون background زائد بشكل كبير.
- إذا كانت مستعمرتان منفصلتان بصريًا: Box لكل واحدة. إذا كانت مستعمرة واحدة متصلة بوضوح: Box واحدة.
- أي Coral واضح داخل الصورة ولا يحصل على Box يعتبر Missing Annotation ويضر التدريب.
- الصور التي لا تحتوي Coral تظل داخل الداتا كـ Negative Images بدون Bounding Boxes.
- استخدام أداة Annotation موحدة مثل CVAT أو Roboflow أو Label Studio مع تعليمات Annotation مكتوبة.

قاعدة الجودة: Consistency أهم من المثالية. نفس القاعدة يجب أن تُطبق على كل الصور، خصوصًا في الحالات الحدودية مثل الشعاب المتداخلة أو الجزئية.

2.5 Dataset Analysis Before Split

- حساب عدد الـ coral instances وليس عدد الصور فقط.
- تحليل Bounding Box area distribution لمعرفة نسبة small / medium / large objects.
- تحليل Aspect Ratio للـ boxes لاكتشاف labels غير طبيعية.
- قياس نسبة الصور السلبية وصور المشاهد المزدحمة.
- تحديد أي ظروف ناقصة: different cameras، far distance، small coral، turbid water، low light.

2.6 Train / Validation / Test Split

- بداية مناسبة: 70/15/15 أو 80/10/10؛ النسبة أقل أهمية من منع الـ leakage.
- Split حسب مصدر الفيديو أو dive/site/sequence وليس Frame عشوائي فقط.
- إذا أمكن، اجعل Test Set أصعب قليلًا ويحتوي ظروفًا ومواقع لم يرها الموديل في التدريب.
- لا تعمل Augmentation قبل الـ split؛ الـ augmentation يكون على Train فقط.

2.7 Detection Augmentation

- Horizontal flip وsmall rotation إذا كانت منطقية للمشهد.
- Brightness / contrast variation لمحاكاة اختلاف الإضاءة.
- Blue-green color cast وreduced contrast لمحاكاة underwater appearance.
- Mild blur وmild haze/turbidity بشكل واقعي.
- Scale / crop مع التأكد أن الـ Bounding Boxes تتحدث بشكل صحيح.
- تجنب augmentation مبالغ فيه يجعل الشعاب غير واقعية أو يخفي خصائصها.

2.8 Final YOLO Dataset Structure

```
coral_detection/
├── images/
│   ├── train/
│   ├── val/
│   └── test/
├── labels/
│   ├── train/
│   ├── val/
│   └── test/
└── data.yaml
```

• كل image لها ملف .txt بنفس الاسم داخل labels. كل سطر يمثل Bounding Box واحدة.

```
# YOLO label format
class_id  x_center  y_center  width  height
0 0.452 0.381 0.218 0.307


# data.yaml
path: /content/coral_detection
train: images/train
val: images/val
test: images/test
names:
  0: coral
```

2.9 Detection Data Acceptance Criteria

• No obvious missing boxes in reviewed samples.

• No systematic loose/tight annotation inconsistency.

• Train/Val/Test separated by source/sequence to prevent leakage.

• Hard conditions represented in Train and intentionally measured in Test.

• Negative images included.

• Dataset summary saved: images, instances, object sizes, conditions, splits.

Raw Data -> Frame Extraction -> Cleaning -> Bounding Boxes -> QC -> Split -> Augment Train -> YOLO Format -> Ready for Training

3. Object Detection Model Training

الهدف: اكتشاف وجود الشعاب المرجانية وتحديد مكان كل instance داخل الصورة بأفضل توازن بين الدقة والسرعة.

3.1 Baseline & Experiments

- اختيار Baseline واحد أولًا مثل YOLOv8 أو YOLO11 بحجم مناسب للـ GPU.
- استخدام pre-trained weights ثم fine-tuning على coral dataset.
- تسجيل كل تجربة: seed، augmentation، learning rate، optimizer، epochs، batch size، image size، model size.
- حفظ best checkpoint بناءً على Validation metric وليس آخر epoch فقط.
- عدم تغيير عدة متغيرات في نفس التجربة؛ غيّر عاملًا واحدًا أو مجموعة منطقية حتى تعرف سبب التحسن.

3.2 Detection Evaluation

Metric / Check	What it tells us	Why it matters
mAP@50	جودة الكشف عند IoU=0.50	مقياس سهل للمقارنة السريعة
mAP@50:95	متوسط الأداء عبر IoU thresholds أصعب	أفضل قياس عام لجودة localization
Precision	كم detection كان صحيحًا	يكشف كثرة False Positives
Recall	كم coral حقيقي تم اكتشافه	مهم جدًا لتقليل Missed Coral
IoU / Box quality	مدى تطابق الـ predicted box مع ground truth	يؤثر مباشرة على جودة crop للـ classifier
Scenario metrics	أداء منفصل حسب الظروف	يكشف نقاط الفشل المخفية وراء المتوسط

3.3 Detection Error Analysis

- False Positive: ما الأشياء التي يعتقد الموديل أنها Coral؟ مشابه؟ rocks، plants، texture
- False Negative: أي Coral يفوته؟ small، far، low light، partially visible؟
- Localization Error: هل يكتشف Coral لكن الـ box واسعة أو تقص جزءًا منها؟
- Crowded Scene Error: هل يدمج مستعمرتين في Box واحدة أو يفقد بعض instances؟

• اعمل Gallery للأخطاء بدل الاعتماد على الأرقام فقط.

Iteration Loop: إذا كانت المشكلة small coral، قد تحتاج صور بدقة أعلى أو image size أكبر أو مزيدًا من small-object examples. إذا كانت المشكلة turbid water، زد أمثلة واقعية من هذه الظروف بدل تغيير الموديل مباشرة.

Classification Track

4. Classification Data Preparation

الهدف: تجهيز صور تمثل coral species بشكل قريب من الـ crops التي سيخرجها الـ Detection Model وقت التشغيل الحقيقي.

4.1 Define Species Classes

• تحديد قائمة الـ species/classes النهائية قبل التدريب، مع اسم موحد لكل Class.

• مراجعة أي أسماء علمية أو labels مكررة/مترادفة حتى لا يصبح نفس النوع في أكثر من Class.

• حصر عدد الصور لكل Class وتحديد الأنواع ذات العينات القليلة.

• الصور غير المؤكدة أو التي لا يمكن تمييز نوعها لا تُجبر على Class خاطئة؛ توضع للمراجعة أو تستبعد.

4.2 Build Realistic Coral Crops

• المصدر الأول: صور الـ Classification Dataset الجاهزة المصنفة حسب النوع.

• المصدر الثاني: Crops من صور Detection التي نعرف نوع الشعاب فيها.

• المصدر الثالث لاحقًا: predicted crops من أفضل Detector لمحاكاة الأخطاء الواقعية في الـ bounding boxes.

• أضف margin بسيط حول الـ box (مثل 5-15% عند التجربة) حتى لا تقص الخصائص الخارجية للشعاب ولتحاكي detector crops.

• لا تجعل كل صور التدريب perfect centered crops فقط؛ الـ deployment سيحتوي background، box offsets، blur وتغيرات إضاءة.

4.3 Cleaning & Label Verification

- حذف الصور التالفة أو التي لا يظهر فيها coral بوضوح كافٍ للتصنيف.
- مراجعة Label النوع، خصوصًا الأنواع المتشابهة مورفولوجيًا.
- اكتشاف duplicates وnear-duplicates.
- تسجيل source_id لكل colony/sequence، image/video، dataset: crop إن أمكن.

4.4 Classification Split without Leakage

- لا تقسّم صورًا لنفس coral colony أو frames متجاورة بين Train وTest.
- Split حسب source/video/site/colony عندما تكون هذه المعلومات متاحة.
- حافظ على وجود كل Class في Train وValidation وTest قدر الإمكان.
- استخدم stratification على مستوى الـ group، وليس random image split فقط.

4.5 Class Balance

- اعمل جدول Count لكل Class قبل التدريب.
- إذا كان imbalance بسيطًا: augmentation وتقييم per-class قد يكونان كافيين.
- إذا كان imbalance كبيرًا: weighted sampler، weighted loss أو oversampling للـ minority classes بشكل محسوب.
- لا تحاول مساواة الأعداد بشكل أعمى بتكرار نفس الصور كثيرًا؛ هذا يرفع overfitting.

4.6 Preprocessing & Input Shape

- Convert to RGB.
- Resize إلى input size مناسب للـ architecture؛ 224x224 بداية شائعة لـ MobileNet/EfficientNet variants، مع الالتزام بإعدادات الـ pretrained weights المستخدمة.
- Normalize باستخدام mean/std المطلوبة من الـ pretrained model.
- في PyTorch الشكل يكون عادة [Batch, 3, Height, Width].
- لا تستخدم resize يشوه الـ aspect ratio بشدة إذا كانت البنية الشكلية للـ coral مهمة؛ يمكن استخدام pad/center crop حسب التجربة.

4.7 Classification Augmentation

• Horizontal flip، small rotation، random resized crop ضمن حدود منطقية.

• Brightness / contrast / color jitter محدود.

• Underwater blue-green cast، mild blur، reduced contrast، slight haze/turbidity.

• التأكد أن الـ augmentation لا يزيل texture/branch structure أو الخصائص التي تفرق بين الأنواع.

4.8 Unknown / Other Strategy

• الـ classifier المغلق Closed-set مجبر على اختيار واحدة من الـ known classes حتى لو ظهر نوع جديد.

• في مرحلة متقدمة يمكن إضافة Other/Unknown class إذا توفر data مناسب.

• أو استخدام confidence threshold بحيث prediction منخفض الثقة يتم عرضه كـ Unknown / Needs Review بدل إعطاء نوع خاطئ بثقة زائفة.

• يجب ضبط الـ threshold على Validation data وليس اختياره عشوائيًا.

4.9 Final Classification Dataset Structure

```
coral_classification/
├── train/
│   ├── Acropora/
│   ├── Porites/
│   ├── Montipora/
│   └── .../
├── val/
│   ├── Acropora/
│   ├── Porites/
│   └── .../
└── test/
    ├── Acropora/
    ├── Porites/
    └── .../
```

4.10 Classification Data Acceptance Criteria

• Class names and taxonomy fixed and documented.

• Labels manually verified on a representative sample and ambiguous images handled.

• Splits separated by source/sequence/colony when possible.

• Class imbalance quantified and mitigation chosen.

• Training images include both clean crops and realistic detector-like crops.

• Preprocessing exactly matches the selected pretrained model requirements.

Species Labels -> Clean Images -> Coral Crops -> QC -> Group Split -> Balance -> Preprocess -> Augment Train -> Ready for Classifier

5. Classification Model Training

الهدف: تحديد نوع الشعاب المرجانية لكل crop مكتشف، مع معرفة الأنواع التي يخلط بينها الموديل وعدم الاكتفاء بالـ Accuracy العامة.

5.1 Baseline Strategy

• ابدأ بـ architecture واحدة كـ baseline: MobileNet أو EfficientNet أو ConvNeXt حسب الموارد المطلوبة.

• استخدم Transfer Learning من pretrained weights.

• مرحلة أولى: train classifier head أو freeze معظم backbone لفترة قصيرة.

• مرحلة ثانية: fine-tune جزء أكبر من backbone بـ learning rate أصغر عند الحاجة.

• لا تقارن architectures قبل وجود pipeline ثابتة للـ data split/preprocessing والتقييم.

5.2 Classification Evaluation

Metric / Check	What it tells us	Why it matters
Accuracy	نسبة الصور المصنفة بشكل صحيح	مفيد لكن قد يخفي مشاكل imbalance
Precision per class	مدى صحة تنبؤات كل نوع	يكشف كثيرة الـ false positives classes
Recall per class	كم عينة حقيقية من النوع تم إيجادها	يكشف الأنواع التي يفوتها الموديل
F1-score	توازن Precision وRecall	أفضل للمقارنة في imbalance
Confusion Matrix	أي الأنواع يخلط بينها الموديل	أساسي لفهم species بين similarity
Macro F1	وزنًا متساويًا Class يعطي كل	مهم عندما أعداد classes غير متوازنة
Top-k accuracy	هل النوع الصحيح ضمن أعلى تنبؤات	مفيد للتحليل أو human review

5.3 Classification Error Analysis

- راجع الأخطاء بين كل زوج Classes في Confusion Matrix.
- افصل أخطاء الجودة السيئة عن أخطاء التشابه الحقيقي بين الأنواع.
- اختبر clean crops مقابل detector-generated crops لمعرفة أثر أخطاء الـ boxes.
- راقب confidence calibration: predictions الخاطئة الواثقة أخطر من predictions المترددة.
- أنشئ per-class gallery للـ correct/incorrect examples.

6. Detection + Classification Integration

Input Image -> YOLO Detection -> Bounding Boxes -> Crop + Margin -> Resize/Normalize -> Classifier -> Species + Confidence -> Draw Final Result

- تشغيل detector على الصورة أو frame.
- لكل box فوق detection threshold: قص المنطقة مع margin مناسب وحدود الصورة.
- تطبيق preprocessing الخاص بالـ classifier فقط على الـ crop.
- تشغيل classification وإرجاع species confidence.
- إذا classification confidence أقل من threshold: Unknown/Review عند استخدام هذه السياسة.
- رسم box + species name + detection confidence + classification confidence على الصورة الأصلية.

6.1 End-to-End Evaluation

- Detection success rate: هل تم إيجاد coral أصلًا؟
- Classification accuracy on ground-truth crops: يقيس classifier وحده.
- Classification accuracy on detected crops: يقيس أثر detector الحقيقي.
- End-to-End correct result: coral detected + localized بشكل مقبول + species صحيح.
- Error attribution: Detection error أم Crop error أم Classification error.

7. Video Inference

- قراءة الفيديو Frame-by-Frame وتشغيل الـ integrated pipeline.
- تسجيل FPS وprocessing time per frame.
- حفظ annotated video مع species labels.
- تقييم box stability وclassification stability عبر الفريمات.
- اختبار crowded scenes، camera motion، turbid water، low light، clear water.

8. Real-Time Inference

- تشغيل pipeline على camera / ROV / live stream.
- قياس FPS وLatency على الـ target hardware.
- تجربة model size وimage size مختلفة لتحقيق Speed-Accuracy tradeoff.
- استخدام optimized runtime / model export / FP16 عند الحاجة.
- تسجيل GPU/CPU/Memory usage ومراقبة الثبات الطويل.

9. Final Evaluation & Error Analysis

- احتفظ بـ Final Test Set لا يتم استخدامه في tuning.
- اعرض النتائج حسب condition وليس overall average فقط.
- اختبر أنواع شعاب متعددة، أحجام مختلفة، backgrounds، low light، clear/turbid water مختلفة وكاميرات مختلفة.
- حدد أهم 5 failure modes وأولوية إصلاح كل منها.
- وثق Limitations، خاصة الأنواع غير الموجودة في training، ضعف الصور، domain shift بين datasets والكاميرا الحقيقية.

10. Recommended Experiment Order

ID	Experiment / Milestone

D1	Detection dataset audit + annotation QC
D2	YOLO baseline at one image size
D3	Detection error analysis by condition
D4	Improve data / image size / augmentation only where evidence shows weakness
C1	Classification dataset audit + taxonomy verification
C2	MobileNet/EfficientNet/ConvNeXt baseline - choose one first
C3	Confusion Matrix + per-class analysis
C4	Add realistic detector-like crops
I1	Integrate best detector + classifier
V1	Recorded video test
R1	Real-time optimization
F1	Final unseen test + report

11. Final Deliverables

• Detection dataset summary + annotation guideline.

• Trained YOLO model + experiment log + detection evaluation report.

• Classification dataset summary + class distribution + split manifest.

• Trained classification model + confusion matrix + per-class metrics.

• Integrated detection-classification inference script/notebook.

• Annotated test video.

• Real-time demo with FPS/latency measurements.

• Final report: results, error analysis, limitations, next improvements.

المبدأ الأساسي للمشروع: إذا ظهرت مشكلة في النتائج، لا تغيّر الموديل مباشرة. أولًا حدد هل سببها Data، Annotation، Split، Detection، Crop، Classification أم Deployment. هذا يجعل التحسين مبنيًا على دليل بدل التجربة العشوائية.