Coral Reef Dataset Audit, Diversity Analysis & Gap Mitigation Guide

دليل عملي مدمج لفحص الداتا، قياس التنوع، اكتشاف الحالات الناقصة، ومعالجة الفجوات قبل التدريب

الهدف من الملف

تحويل فحص التنوع من تقييم بصري عشوائي إلى نظام قياس ثابت وقابل للتكرار. يبدأ بتعريف قواعد واضحة للوسم، ثم يقيس التغطية داخل Detection وClassification، ثم يحدد الفجوات، وأخيرًا يقرر هل الحل هو Real Data Collection أو Targeted Augmentation أو Synthetic Data.

هذا المرجع يدمج بالتفصيل محتوى ملفي Dataset Diversity Audit وData Audit & Diversity Check في Workflow واحد دون تكرار غير ضروري.

خريطة الدليل

القسم	السؤال الذي يجيب عنه
1. Scope & Principles	لماذا عدد الصور ليس كافيًا؟
2. Audit Schema	ما الأعمدة التي أسجلها لكل صورة؟
3. Labeling Guide	كيف أحدد Small / Turbid / Low Light ... بشكل ثابت؟
4. Pilot Audit	كيف أثبت القواعد قبل مراجعة مئات الصور؟
5. Diversity Measurements	كيف أحسب النسب والتغطية؟
6. Detection Audit	ما الذي أستخرجه تلقائيًا من Bounding Boxes؟
7. Classification Audit	كيف أفحص التنوع داخل كل Coral Class؟
8. Cross-Condition Coverage	كيف أكتشف Small + Turbid أو Class + Angle الناقصة؟
9. Baseline Error Analysis	كيف أستخدم الموديل نفسه لاكتشاف ضعف الداتا؟
10. Gap Prioritization	أي فجوة أصلح أولًا؟
11. Gap Mitigation	متى أجمع Real Data ومتى أستخدم Augmentation/Synthetic؟
12. Split & Leakage Control	كيف أمنع نتائج وهمية؟
13. Final Reporting	ما التقرير النهائي المطلوب قبل التدريب؟

1. المبادئ الأساسية للفحص

عدد الصور وحده لا يضمن جودة الداتا. 10,000 صورة من نفس الفيديو أو نفس الكاميرا قد تمثل نطاقًا بصريًا أضيق من 2,000 صورة ملتقطة في مواقع وكاميرات وظروف مختلفة. الهدف هو قياس Coverage للظروف التي سيشاهدها النظام في الاستخدام الحقيقي.

- قِس التنوع، لا تعدّ الملفات فقط.
- عرّف مسبقًا ما هي الظروف المتوقعة في التشغيل الحقيقي: إضاءة، عكارة، مسافة، كثافة، زوايا، كاميرات، خلفيات، أنواع شعاب.
- أي Gap يجب أن تتحول إلى Action واضح: Collect / Augment / Synthesize / Re-label / Ignore with justification.
- الـTest Set يجب أن يبقى واقعيًا وغير مصنوع صناعيًا قدر الإمكان.

قاعدة حاسمة

لا تحتاج كل الفئات إلى توزيع 50/50. المطلوب توزيع يمثل الواقع ويحتوي عددًا كافيًا من الحالات الصعبة حتى يمكن تدريب النموذج وقياس robustness.

2. تصميم Data Audit Sheet

ابدأ بعينة Representative من كل المصادر. إذا كانت الداتا كبيرة، لا تأخذ أول 500 صورة؛ اسحب عينة موزعة من الفولدرات، الفيديوهات، المواقع، والتواريخ/الكاميرات إن توفرت.

Image	Coral Class	Size	Lighting	Water	Distance	Density	Visibility	Background	Angle	Color Cast	Camera	Confidence	Notes
img_001	Acropora	Small	Low	Turbid	Far	Crowded	Partial	Rock	Side	Blue	Cam1	High	Strong haze
img_002	Porites	Large	Normal	Clear	Near	Single	Full	Sand	Front	Normal	Cam1	High	Clear details
img_003	Pavona	Medium	Normal	Moderate	Medium	Multiple	Full	Mixed	Top	Green	Cam2	Medium	Borderline clarity

لـDetection إذا كان عندك Class واحدة فقط باسم coral، يمكن أن يكون Coral Class غير مستخدم. أما في Classification فهو أساسي ويجب أن يأتي من Label موثوق، لا من التخمين.

3. Annotation Guide - قواعد الحكم على كل خاصية

3.1 Size - حجم الشعاب داخل الصورة

في Detection الأفضل حساب الحجم من Bounding Box بدل الاعتماد على العين. استخدم النسبة التالية كأداة Audit:

```
relative_box_area = (box_width * box_height) / (image_width * image_height)

Example audit bins:
Small  < 2%
Medium = 2% to 10%
Large  > 10%
```

هذه الحدود ليست معيارًا علميًا عامًا؛ هي bins تحليلية مبدئية. بعد رؤية توزيع داتا المشروع يمكن تعديلها ثم تثبيتها على كامل التقرير.

3.2 Lighting - الإضاءة

التعريف العملي	القيمة
إضاءة قوية والتفاصيل واضحة؛ لا يوجد فقد بسبب الظلام.	Bright
التفاصيل الأساسية ظاهرة بإضاءة طبيعية للاستخدام المتوقع.	Normal
أجزاء مهمة مظلمة أو بدأ فقد تفاصيل/texture بسبب قلة الضوء.	Low

يمكن استخدام Mean Brightness / Histogram كمؤشر مساعد فقط لا تجعل threshold آليًا وحيدًا لأن underwater color cast قد يخفض أو يرفع القيم دون أن يعكس وضوح التفاصيل الحقيقي.

3.3 Water / Turbidity - صفاء المياه

التعريف العملي	القيمة
حواف وتفاصيل واضحة، contrast جيد، haze محدود.	Clear
Haze بسيط أو فقد واضح لكن غير شديد في التباين/التفاصيل.	Moderate
عكارة/ضبابية واضحة وفقد تفاصيل خصوصًا للأجسام البعيدة.	Turbid

وجود فئة Moderate أفضل من إجبار كل صورة على Clear أو Turbid عندما تكون الحالة borderline.

3.4 Distance - المسافة البصرية

التعريف	القيمة
الشعاب كبيرة نسبيًا والتفاصيل الدقيقة واضحة.	Near
حجم ووضوح متوسطان.	Medium
الشعاب صغيرة نسبيًا وفقدت جزءًا من التفاصيل بسبب المسافة/الماء.	Far

> **تنبيه**
> Distance هنا Proxy بصري وليس قياسًا بالمتر. إذا لم تتوفر depth/distance metadata حقيقية فلا تكتب أمتارًا ولا تدّعي قياسًا فيزيائيًا.

3.5 Density - كثافة المشهد

```
1 coral       -> Single
2-5 corals    -> Multiple
>5 corals     -> Crowded
```

يمكن تعديل الحدود بعد رؤية توزيع الداتا. في Detection استخرجها تلقائيًا من عدد الـBounding Boxes؛ ثم راجع الحالات المتداخلة بصريًا.

3.6 Visibility / Occlusion

تعريف تقريبي	القيمة
أكثر من 90% من الكائن ظاهر.	Full
حوالي 50-90% ظاهر.	Partial
أقل من 50% ظاهر أو جزء أساسي محجوب.	Heavy Occlusion

أسباب الحجب: coral أخرى، صخور، أسماك، vegetation، حافة الصورة، أو تداخل داخلي في المستعمرة.

3.7 Background

استخدم فئات قليلة: Sand / Rock / Plants-Seagrass / Other Coral / Water / Mixed. قيّم البيئة المحيطة بالـROI أو Bounding Box، لا الصورة كلها فقط.

3.8 Angle

استخدم Front / Side / Top / Oblique لا تبني taxonomy معقدة للزاوية؛ الهدف قياس هل الموديل يرى النوع من أكثر من viewpoint.

Color Cast 3.9

فئات عملية: Normal-Balanced / Blue Dominant / Green Dominant / Strong Color Loss. هذه مهمة خصوصًا لأن النموذج قد يتعلم اللون كshortcut بدل morphology للClassifier.

Camera / Source / Location 3.10

إذا توفرت metadata، سجّل Video ID، Location، Source، Camera ID. هذه الحقول مهمة لقياس domain diversity ومنع leakage بين train/test.

Confidence + Notes 3.11

لكل قرار يدوي سجّل High / Medium / Low Confidence. أي Low Confidence يدخل Review Queue بدل إجبار المراجع على label غير موثوق.

Image	Field	Decision	Confidence	Notes
001	Water	Turbid	High	Strong haze and low contrast
002	Water	Moderate	Low	Borderline clear/turbid - review again
003	Angle	Oblique	Medium	Between side and top

4. Pilot Audit — لا تبدأ بـ500 صورة مباشرة

ابدأ بـ50 صورة فقط لضبط القواعد. هذا يقلل inconsistency قبل الاستثمار في وسم مئات الصور.

```
1. Take 50 representative images
        ↓
2. Define initial audit rules
        ↓
3. Label the 50 images
        ↓
4. Find ambiguous cases
        ↓
5. Refine definitions
        ↓
6. Freeze the labeling guide
        ↓
7. Audit 300-500 representative images
```

لو تعمل ضمن فريق، اجعل شخصين يوسمان أول 30-50 صورة مستقلين ثم ناقش الاختلافات. الهدف ليس حساب metric رسمية فقط، بل اكتشاف التعريفات الغامضة قبل التوسع.

5. قياس التنوع - Single-Factor Distributions

بعد اكتمال العينة احسب النسب لكل عامل. هذا يعطي أول صورة عن الانحيازات الواضحة.

Factor	Example Distribution	ملاحظة
Size	Small 9% | Medium 34% | Large 57%	Small objects قد تكون underrepresented.
Lighting	Bright 18% | Normal 70% | Low 12%	Low-light coverage ضعيفة.
Water	Clear 81% | Moderate 14% | Turbid 5%	Turbid data قليلة جدًا.
Distance	Near 62% | Medium 29% | Far 9%	Far-distance coverage ضعيفة.
Density	Single 55% | Multiple 37% | Crowded 8%	Crowded scenes قليلة.

لا تستنتج من النسبة وحدها

وجود 100 صورة Turbid و200 صورة Small لا يعني أنك تملك Small + Turbid. النقص الحقيقي غالبًا يظهر في التركيبات.

6. أهم خطوة لاكتشاف النقص - Cross-Condition Coverage Matrix

ابنِ جداول تقاطع بين العوامل التي تمثل مخاطر حقيقية في التطبيق.

Condition	Count	Status	Action
Small + Clear	120	OK	No immediate action
Small + Turbid	8	Gap	Collect / targeted augmentation
Small + Low Light	11	Gap	Increase coverage
Far + Turbid	5	Critical Gap	Prefer real data
Crowded + Low Light	3	Critical Gap	Collect difficult scenes
Partial + Rock background	70	OK	Monitor performance

أهم تقاطعات مقترحة لمشروع الشعاب:

- Size × Water
- Size × Distance
- Lighting × Water
- Density × Visibility
- Background × False Positives
- Camera/Source × Performance

- Class × Size
- Class × Angle
- Class × Water
- Class × Visibility

7. Detection Audit - ما يمكن قياسه تلقائيًا

لو annotations بصيغة YOLO/COCO، جزء كبير من الـAudit يمكن استخراجه من الـlabels مباشرة.

Metric / Check	كيف يحسب	لماذا مهم
Bounding-box size distribution	relative box area	يكشف نقص small objects.
Objects per image	count boxes/image	يكشف Single/Multiple/Crowded.
Aspect ratio distribution	w/h	يكشف annotations غريبة أو قصص bounding boxes.
Negative image ratio	images with zero boxes	يساعد تقليل false positives.
Box edge proximity	box touching image borders	يكشف partial objects / cropping.
Very tiny / huge boxes	extreme percentiles	تحتاج مراجعة annotation.
Duplicate / near-duplicate frames	hash/embedding similarity	مهم جدًا إذا الداتا من فيديو.

Annotation Quality Control 7.1

- Coral موجودة بدون Box؟
- Box على rock/fish بدل coral؟
- Box واسعة جدًا وفيها background كثير؟
- Box تقص جزءًا مهمًا من coral؟
- Duplicate boxes على نفس الكائن؟
- Policy واحدة للحالات المتلاصقة أم annotation غير consistent؟

قاعدة

Bad Labels → Bad Model. زيادة epochs أو تغيير architecture لن يصلح annotation policy غير متسقة.

Negative Images 7.2

أضف صورًا واقعية لا تحتوي Coral: Sand / Rocks / Fish / Seagrass / Water / debris حسب البيئة. الهدف تعليم detector أن البيئة البحرية ليست كلها coral.

8. Classification Audit - التنوع داخل كل Class

في Classification لا يكفي أن تقول لكل class عدد كبير. يجب قياس الظروف داخل كل نوع، لأن النوع قد يكون ممثلًا فقط من زاوية واحدة أو مياه صافية.

Class	Small	Low Light	Turbid	Partial	Top view	Different sources
Acropora	120	90	60	70	85	4
Porites	140	80	50	65	72	3
Pavona	35	8	4	9	12	1

المثال يوضح أن Pavona ليست فقط أقل عددًا؛ هي أيضًا شبه غائبة تحت Low Light / Turbid / Partial وفي مصادر متعددة. هذا gap أخطر من مجرد class count.

Class Balance 8.1

افحص عدد الصور/الـcrops لكل نوع. إذا كان imbalance شديدًا، لا تعالجه تلقائيًا بالـoversampling فقط؛ افحص أولًا هل الفئة النادرة ناقصة في كل الظروف أم في ظروف محددة.

خيارات المعالجة: targeted augmentation، Balanced Sampler، Weighted Loss للفئات النادرة، وجمع real samples إضافية.

Detector-like Crops 8.2

درّب classifier على crops تشبه ما سيخرجه detector في الحقيقة، وليس فقط صورًا مثالية tightly cropped. احتفظ بجزء من background وأضف padding صغيرًا ثابتًا/موزعًا أثناء التدريب.

9. اكتشاف التكرار والتنوع البصري الحقيقي

الفيديو قد ينتج آلاف frames متشابهة. استخدم perceptual hashes أو embeddings (مثل DINO/CLIP features) وclustering لاكتشاف near-duplicates وتقدير التنوع البصري.

```
10,000 near-identical frames  ≠  10,000 diverse examples

Goal: maximize visual/domain coverage, not raw file count.
```

التكرار لا يضر فقط الحجم؛ قد يسبب leakage إذا frames متجاورة ذهبت إلى train وtest.

10. Baseline Model as a Data Diagnostic Tool

بعد أول baseline، لا تكتفِ بـmAP أو Accuracy العامة. قسّم الـtest set حسب الظروف واحسب الأداء لكل شريحة.

Condition	Example Performance	Interpretation
Clear Water	Recall 91%	Strong
Turbid Water	Recall 58%	Weak - inspect data coverage
Large Coral	Recall 94%	Strong
Small Coral	Recall 49%	Critical weakness
Normal Light	Recall 93%	Strong
Low Light	Recall 55%	Weak
Crowded Scenes	Recall 61%	Weak / occlusion issue

إذا Small + Turbid + Low Light ضعيفة في الداتا وفي الأداء، فهذا دليل قوي أن المشكلة Dataset Gap وليست مجرد اختيار model.

Classification Error Slices 10.1

احسب Macro-F1 / Recall per class ثم إضافي داخل كل slice + class: Pavona + Turbid، Acropora + Far، Porites + Side view ... وهكذا.

11. Gap Prioritization - أصلح ماذا أولًا؟

ليس كل نقص يستحق نفس الجهد. رتّب الفجوات حسب Impact × Frequency × Difficulty.

Priority	الوصف	مثال
P0 - Critical	حالة متوقعة كثيرًا + أداء ضعيف + قليلة في الداتا	Small coral in turbid water
P1 - High	حالة مهمة لكن أقل تكرارًا أو يمكن محاكاتها جزئيًا	Low-light crowded scenes
P2 - Medium	تؤثر على robustness لكن ليست core deployment condition	Rare background type
P3 - Low	نادرة جدًا أو خارج نطاق النظام الحالي	Camera/domain not planned for deployment

قرار هندسي

اربط الأولوية بالـdeployment target. لو النظام سيعمل في Red Sea ومياه صافية غالبًا، لا تجعل synthetic turbidity نصف الداتا لمجرد التوازن.

12. معالجة النقص - Real Data vs Augmentation vs Synthetic Data

12.1 Real Data Collection - الخيار الأقوى

يفضل جمع بيانات حقيقية عندما تكون الفجوة Domain حقيقية لا يمكن محاكاتها بأمان.

- Different cameras / sensors
- Different locations / reef sites
- Different depths
- Real turbid water
- Real low-light scenes
- Far-distance coral
- New backgrounds / habitats
- New source or season if relevant

قاعدة

Augmentation لصورة Camera A لا تساوي وجود Camera B حقيقية. كذلك تصغير coral قريبة لا يساوي coral بعيدة حقيقية بسبب haze وفقد التفاصيل.

12.2 Targeted Data Augmentation

Missing Factor	Possible Augmentation	حدود الاستخدام
Lighting	Brightness / Contrast / Gamma / Exposure	لا تمحُ texture أو تغير morphology.
Color Cast	Hue/Saturation / RGB shifts / Color Jitter	اجعل التغيرات ضمن underwater realism.
Turbidity	Mild haze / blur / contrast reduction / color attenuation / noise	لا تعتبره بديلًا كاملًا لreal turbid data.
Distance / Size	Scale / resize / random zoom / mosaic	Far real scene لها physics مختلفة.
Visibility / Occlusion	Cutout / Random Erasing / occluders	لا تحجب السمات التشخيصية دائمًا.
Angle	Small rotation / affine / perspective	تجنب transformations غير منطقية.
Density	Mosaic / careful Copy-Paste	تأكد من منطق الحجم والإضاءة والتداخل.
Minority classes	Class-targeted augmentation	لا تجعل duplicates مصطنعة هي معظم الفئة.

12.3 Synthetic Data

يمكن استخدام compositing أو generative methods لإضافة ظروف ناقصة، لكن تعامل معها كوسيلة دعم للتدريب لا كدليل على generalization.

- Train: يمكن أن يحتوي Real + Synthetic.
- Validation: يفضل Mostly Real.
- Test: Real only قدر الإمكان.
- سجل source لكل synthetic sample حتى تستطيع قياس تأثيرها في ablation.

12.4 متى لا تستخدم Augmentation؟

- لإنشاء Camera domain جديد بالكامل
- لاستبدال taxonomy/label ناقصة
- لتعويض annotation errors
- لإنشاء زاوية/شكل بيولوجي غير موجود بشكل موثوق
- إذا التغيير قد يغير خصائص النوع التي يعتمد عليها classifier

13. Data Leakage Prevention

هذه نقطة حاسمة خصوصًا مع الفيديو لا تقسّم frames عشوائيًا إذا كانت متجاورة أو لنفس coral instance.

```
Wrong:
Video A frame 001 -> Train
Video A frame 002 -> Train
```

```
Video A frame 003 -> Test

Better:
Video A -> Train
Video B -> Validation
Video C -> Test
```

والأفضل إذا كان هدفك generalization: اترك Location أو Source أو Camera كاملة كـExternal Test Set لم تدخل التدريب.

Split Strategy	متى تستخدمها	القوة
Random image split	صور مستقلة فعليًا من مصادر متعددة	أضعف في اختبار domain generalization
Video-level split	الداتا مستخرجة من فيديوهات	يمنع near-frame leakage
Source/Location split	تريد اختبار generalization	أقوى وأكثر واقعية
Camera-level split	تريد robustness للsensor	قوي لاختبار domain shift

Final Dataset Diversity Report .14

قبل بدء التجارب النهائية، أنشئ Report مختصر يحتوي الأرقام التالية:

```
DATASET SUMMARY
----------------
Total images:
Total videos:
Total coral instances:
Number of classes:
Number of sources/locations:
Number of cameras:

SIZE
Small: __%
Medium: __%
Large: __%

LIGHTING
Bright: __%
Normal: __%
Low: __%

WATER
Clear: __%
Moderate: __%
Turbid: __%

DENSITY
Single: __%
Multiple: __%
Crowded: __%

TOP GAPS
1. _____________________
2. _____________________
3. _____________________
```

Gap Action Table 14.1

Gap	Evidence	Priority	Preferred Fix	Success Check
Small + Turbid	8 samples + Recall 42%	P0	Collect real + mild augmentation	Increase real samples; recall improves
Pavona + Low Light	8 samples + class recall weak	P1	Targeted collection / augmentation	Per-class slice F1 improves
Crowded + Low Light	3 samples	P1	Collect video frames	Crowded recall improves
Camera B missing	0 source samples	P0 if deployment uses it	Collect Camera B real data	External camera test

End-to-End Workflow .15

```
1. Define expected real-world conditions
        ↓
2. Sample 50 images
        ↓
3. Define + refine audit rules
        ↓
4. Freeze the labeling guide
        ↓
5. Audit 300-500 representative images
        ↓
6. Calculate single-factor distributions
        ↓
7. Build cross-condition coverage matrices
        ↓
8. Analyze class-specific diversity
        ↓
9. Analyze boxes, density, negatives and duplicates
        ↓
10. Train baseline
        ↓
11. Evaluate by condition / class / source
        ↓
12. Prioritize gaps
        ↓
13. Collect real data or apply targeted augmentation
        ↓
14. Re-audit and retrain
        ↓
15. Freeze final Train / Val / Test splits
```

Quick Checklist قبل تدريب الموديلات .16

- ☐ تم تعريف Annotation Guide ثابتة لكل عامل.
- ☐ تم عمل Pilot على 50 صورة ومراجعة الحالات الغامضة.
- ☐ تم فحص 300-500 صورة Representative أو أكثر حسب حجم الداتا.
- ☐ تم قياس Size / Lighting / Water / Distance / Density / Visibility / Background / Angle / Color Cast.
- ☐ تم تسجيل Source / Camera / Video ID إن أمكن.
- ☐ تم حساب Cross-condition gaps وليس النسب المنفردة فقط.
- ☐ تم فحص التنوع داخل كل Classification class.
- ☐ تم تحليل Bounding Boxes والـNegative Images والـDuplicates.
- ☐ تم منع Video/Source leakage في split.
- ☐ تم تحديد External Test حقيقي إن أمكن.
- ☐ تم تحويل كل Gap إلى Action + Priority + Success Metric.
- ☐ الـSynthetic data ليست جزءًا أساسيًا من الـTest Set.
- ☐ تمت مراجعة الداتا بعد إضافة samples جديدة قبل التدريب النهائي.

17. الخلاصة التنفيذية

الفحص الصحيح يبدأ بتعريف ثابت لما تعنيه كلمات Small وTurbid وLow Light وغيرها، ثم يقيس التغطية داخل الداتا ويبحث عن التركيبات الناقصة، وبعدها يستخدم أخطاء الـbaseline لتأكيد أن النقص مؤثر فعليًا. الحل الأفضل ليس دائمًا زيادة الصور؛ أحيانًا يكون المطلوب مصدر جديد، كاميرا جديدة، فيديو مختلف، أو عدد صغير من الحالات الصعبة ذات قيمة عالية.

الترتيب العملي المقترح: **Measure → Diagnose → Prioritize → Collect/Augment → Re-measure → Train.**