مشروع اكتشاف وتصنيف الشعاب المرجانية

Current Data Inventory & Recommended Action Plan

ملخص ما تم التحقق منه عن مصادر الداتا الثلاثة، وما يجب تنفيذه قبل بدء تجارب الـ Detection وClassification والفيديو.

```
Current Data Sources

1) Object Detection Dataset - Google Drive
2) Classification Dataset - Kaggle / CoralNet + MCR LTER
3) Underwater Video Dataset - Google Drive download
```

الخلاصة التنفيذية

لدينا الآن قاعدة جيدة لبدء المشروع، لكن لا يجب البدء بالتدريب النهائي قبل توحيد الـClass Taxonomy، مراجعة تنوع الداتا، وفصل Train/Validation/Test بطريقة تمنع Data Leakage. أهم مشكلة حالية هي أن Classes الـDetection لا تتطابق مباشرة مع Classes مصدر الـClassification.

1. نظرة عامة على مصادر الداتا الثلاثة | Three Data Sources

المصدر	المهمة الأساسية	ما تم التحقق منه	المشكلة الحالية	الاستخدام المقترح
Detection - Google Drive	Object Detection	صور + JSON Bounding Boxes + Multi-class	يحتاج Class taxonomy توحيد وفحص كامل diversity	تدريب Detector بعد التحويل للصيغة المطلوبة

Kaggle - coral-reef-dataset	Classification / coral image analysis	19.79 GB، 4,508 files، مصادر من CoralNet وMCR LTER	Taxonomy مختلفة + License على Kaggle = Unknown	مصدر Classification أساسي بعد تنظيف وتوحيد الـclasses
Underwater Videos	Video / End-to-End testing	لدينا رابط فيديوهات مخصص للمشروع	لم يتم عمل audit كامل للمحتوى والظروف حتى الآن	اختبار الفيديو، استخراج Frames، وإضافة حالات صعبة عند الحاجة

Object Detection | Detection Dataset الـ2. داتا

تم فتح الداتا فعليًا بعد فك الضغط، وتم التحقق من **Structure** وصور وملفات **Annotation** حقيقية.

```
Dataset/
|-- annotations/
|   |-- Sinularia_*.json
|   |-- WavingHand_*.json
|   |-- Platygyra_*.json
|   `-- ...
`-- image/
    |-- Sinularia/
    |-- WavingHand/
    |-- Sarcophyton/
    |-- Platygyra/
    |-- Favosites/
    `-- Euphflfiaancora/
```

الـ**Classes** الظاهرة حاليًا في فولدر الصور:

- Sinularia
- WavingHand
- Sarcophyton
- Platygyra
- Favosites
- Euphflfiaancora

معلومة مهمة

اسم فولدر الصورة لا يساوي بالضرورة كل محتوى الصورة. الـJSON هو Ground Truth الحقيقي. مثال تم فتحه: صورة باسم Sinularia_110 تحتوي Annotation لـSinularia وAnnotation آخر لـPlatygyra. وصورة WavingHand_71 تحتوي أكثر من نوع وعدة Bounding Boxes.

صيغة الـ**Annotation** التي تم التحقق منها:

```
label
x
y
width
height
```

القيم في العينات هي Pixel coordinates، ولذلك تحتاج Conversion قبل تدريب YOLO أو أي صيغة أخرى تعتمد Normalized coordinates.

ما الذي يجب عمله على **Detection Data**؟ | **Detection Data Actions**

- حساب العدد الحقيقي للصور والـJSON files ومطابقة كل Image مع Annotation.
- استخراج كل labels من JSON وبناء Class Distribution حقيقي، وليس الاعتماد على أسماء الفولدرات.
- مراجعة اسم Euphflfiaancora والتحقق من الـtaxonomy والتهجئة قبل تثبيت الـclass mapping.
- عمل Bounding-box audit: Small / Medium / Large، Single / Multiple / Crowded، وBox quality.
- عمل Diversity Audit: Lighting، water clarity/turbidity، distance، background، visibility، angle، color cast.
- اكتشاف duplicates وnear-duplicates، خصوصًا الصور المتتابعة أو شديدة التشابه.
- تحديد هل سنستخدم الـDetector كـSingle-Class (coral) أم Multi-Class species detector.

التوصية الأقوى للمسار الحالي

بما أن تصميم المشروع الأصلي هو Detection -> Crop -> Classification، فالأكثر اتساقًا أن يكون الـDetector Single-Class باسم coral، ثم يقوم الـClassifier بتحديد النوع. يمكن الاحتفاظ بالـspecies labels الأصلية للبحث والتحليل، لكن

تحويل boxes إلى class=coral يجعل المرحلتين غير متداخلتين وظيفيًا.

3. داتا الـClassification من Classification Dataset | Kaggle

المصدر المشار إليه هو **Coral Reef Image Dataset for Deep Learning-Based Classification and Localization**.

- Kaggle يعرض النسخة الحالية بحجم يقارب 19.79 GB وبإجمالي 4,508 files.
- الداتا مجمعة من مصدرين رئيسيين: CoralNet وMCR LTER.
- MCR LTER - Moorea Labeled Corals يحتوي 2,055 صورة من ثلاثة habitats ومن سنوات 2008-2010، وله point annotations لعدة فئات benthic، منها خمسة أجناس مرجانية: Acropora, Pavona, Montipora, Pocillopora, Porites.
- يوجد ملف combined_annotations_remapped.csv ضمن نسخة Kaggle.
- Kaggle يعرض License = Unknown؛ لذلك يجب مراجعة شروط المصادر الأصلية قبل نشر Dataset مشتقة أو استخدامها تجاريًا.

أهم مشكلة

Classes الـClassification القادمة من CoralNet/MCR LTER لا تتطابق مباشرة مع Classes التي رأيناها في Detection dataset. لذلك لا يجوز دمج المرحلتين قبل إنشاء Unified Taxonomy.

Class Taxonomy | Critical Alignment Issue 4. مشكلة الـ

Detection labels التي ظهرت	Classification labels المؤكدة من MCR LTER	النتيجة
Sinularia, WavingHand, Sarcophyton, Platygyra, Favosites, Euphflfiaancora	Acropora, Pavona, Montipora, Pocillopora, Porites (+ non-coral benthic labels)	Taxonomy mismatch
Species/Genus-like detection labels	Different genus set / point-label source	يجب اختيار Target Species Set موحد قبل التدريب

لو تجاهلنا هذه النقطة قد يصل الـ**Detector** إلى دقة عالية والـ**Classifier** إلى دقة عالية، لكن الـ**Pipeline** النهائية تظل غير منطقية لأن **Crop** لن تكون له **Class** مناسبة داخل **classifier**.

Video Dataset | 5. داتا الفيديو

الفيديوهات تم توفيرها كمصدر مستقل لاختبار النظام على المشاهد المتحركة. حتى الآن لم يتم تنفيذ Audit كامل لها، لذلك لا نفترض أنها متنوعة تلقائيًا.

الاستخدامات المقترحة:

- End-to-End inference: Detection -> Crop -> Classification على كل Frame.
- قياس FPS وLatency وStability عبر الزمن.
- قياس هل نفس coral يتغير تصنيفه بين Frames متتالية (Temporal Instability).
- استخراج Frames مختارة فقط إذا وجدنا نقصًا في Detection training data.
- استخدام فيديو أو مصدر كامل كـExternal Test إن أمكن، وعدم تسريب Frames منه إلى Train.

مهم

عدد Frames الكبير لا يعني Diversity. آلاف الـFrames المتتالية قد تمثل نفس المشهد تقريبًا. لذلك إذا استخرجنا Frames للتدريب يجب استخدام sampling + near-duplicate filtering.

6. ما المفروض نعمله الآن؟ | Recommended Workflow

```
STEP 1  Freeze the project taxonomy
        |
STEP 2  Audit Detection dataset
        |
STEP 3  Audit Classification dataset
        |
STEP 4  Audit Videos / conditions
        |
STEP 5  Build unified Train / Val / Test strategy
        |
STEP 6  Fill only the real data gaps
        |
STEP 7  Train baseline models
        |
STEP 8  Evaluate by condition and class
        |
STEP 9  Run 4 experiment pipelines
        |
STEP 10 End-to-End video + real-time evaluation
```

المرحلة 1 - تثبيت الـFreeze Taxonomy | Target Classes

- قرر بالضبط ما الأنواع التي يجب أن يستطيع النظام النهائي تسميتها.
- راجع أسماء Detection labels علميًا وإملائيًا، وحدد synonym/common-name mapping إن وجد.
- أنشئ جدول Unified Class Map بين كل مصدر والاسم النهائي.
- أي Class غير قابلة للتوحيد: إما Other/Unknown أو تستبعد من النسخة الأولى.

المرحلة 2 - Detection Audit | Detection Audit

- .Exact counts: images, annotations, boxes, boxes per class
- .Box size distribution + crowdedness + negative images
- .ممثل Sample على Visual diversity audit
- .خاطئ object على Annotation errors / missing boxes / boxes
- .Duplicate and near-duplicate analysis
- .class map الـإقفال بعد المطلوب التدريب format إلى JSON تحويل

المرحلة 3 - Classification Audit | Classification Audit

- حساب usable images/crops لكل final class.
- فحص Class imbalance وداخل كل class: size, lighting, angle, visibility, water condition.
- منع split عشوائي يضع صورًا من نفس sequence/source في Train وTest.
- تحضير crops تشبه ما سيخرجه الـDetector، وليس صورًا مثالية فقط.

7. متى نضيف **CoralNet / ReefNet / Data** أخرى؟ | **When to Add More Data**

لا نضيف **Data** جديدة لمجرد زيادة العدد. نضيفها فقط بعد ظهور **Gap** قابلة للقياس.

مصدر إضافي محتمل	الإجراء الأول	**Gap** مكتشفة
مصدر موثق / CoralNet / ReefNet	جمع/تنظيف صور حقيقية لنفس class	Class ناقصة أو قليلة جدًا
فيديوهات/صور حقيقية متنوعة	زيادة small/far examples + targeted augmentation	Small coral recall منخفض
فيديوهات تحت إضاءة مختلفة	Real low-light أولًا ثم realistic augmentation	Low-light ضعيف
مصدر field مختلف	Real turbid samples + mild haze augmentation	Turbid water ضعيف
CoralNet/ReefNet أو dataset جغرافي مختلف	إضافة مصدر مختلف فعليًا	كاميرا/موقع واحد فقط
فيديوهات مستقلة	زيادة sequences للتقييم، لا random frames فقط	Video instability

8. استراتيجية الـ**Train / Validation / Test** | **Splits**

```
TRAIN
- Main labeled data
- Augmentation allowed
```

```
VALIDATION
- Real data
- No synthetic-only evaluation
- Used for checkpoint/model selection

TEST
- Real data only
- Prefer unseen source / location / video
- Never used for tuning
```

قاعدة أساسية

لو عندك Frames من نفس الفيديو، لا توزع Frames متجاورة بين Train وTest. الأفضل Video-level أو Source-level split حتى يكون التقييم حقيقيًا.

9. النتيجة المطلوبة قبل أول تدريب | Definition of Ready

- [ ] Final class list ثابتة ومراجعة.
- [ ] Unified mapping بين Detection وClassification جاهز.
- [ ] Detection annotations تم فحصها وتحويلها بشكل صحيح.
- [ ] Class distribution معروف بالأرقام.
- [ ] Diversity gaps معروفة وليست تقديرية.
- [ ] Train/Val/Test split بدون leakage.
- [ ] External/video test محفوظ خارج التدريب.
- [ ] Baseline metrics وexperiment logging template جاهزين.

10. قرار مقترح للمشروع الحالي | Recommended Decision

المسار المقترح

اجعل Object Detection في النسخة الأساسية Single-Class = Coral، ثم Classification تحدد النوع من crop. هذا يطابق الهدف الأصلي للمشروع ويمنع التكرار بين المرحلتين. بعد ذلك يمكن عمل تجربة إضافية Multi-Class Detector للمقارنة،

لكن ليست هي الـbaseline الأساسية.

```
Underwater Image / Video
        |
        v
Single-Class Coral Detector
        |
        v
Bounding Box + ROI Crop
        |
        v
Unified Coral Species Classifier
        |
        v
Species + Confidence
        |
        v
Video / Real-Time Output
```

Sources Reviewed | المصادر التي بُني عليها هذا الملخص

- Google Drive detection folder supplied by the project owner - structure, images, and JSON .annotations were inspected directly
- Kaggle: coral-reef-dataset by jxwleong - data card and current file summary.
- MCR LTER: Moorea Labeled Corals - official dataset description and coral genera/annotation details.
- Project underwater video download source - retained as a dedicated video corpus; detailed diversity .audit is still pending

ملاحظة: المعلومات التي لم يتم التحقق منها مباشرة (خصوصًا التنوع الكامل للفيديوهات والأعداد النهائية لكل Detection class) تم تمييزها كمهام Audit، ولم يتم افتراضها.